

[연구 3호 서식]

연구결과 보고서			
관리 번호	계약시 부여		
사 업 명	2023 년 연구사업		
과 제 명	국문	딥러닝을 활용한 식품소비자 불만족과 요청사항 연구; 콜센터의 고객 질의-응답 텍스트 분석	
	영문	A Study on Food Consumer Complaints and Requests Using Deep Learning	
주관연구 책임자	성 명	소속 및 부서	전 공
	윤호정	세종대학교 경영대학	마케팅
총연구기간	2023 년 2 월 1 일 - 2024 년 1 월 31 일 (1 년)		
총참여연구원	5 명 (책임연구원: 1 명, 연구원: 1 명, 연구보조원: 3 명)		
<p>2024 년도 연구사업에 의하여 수행중인 연구과제의 연구결과 보고서를 붙임과 같이 제출합니다.</p> <p style="text-align: center;">2024 년 1 월 19 일</p> <p>붙임 : 1. 연구결과 보고서 1부 2. 연구결과 보고서 수록 파일 1부</p> <p style="text-align: center;">주관연구책임자 윤 호 정 (인)</p> <p style="text-align: center;">연구기관장 유 상 호 (인)</p> <p style="text-align: center;">재단법인 오뚜기함태호재단 귀중</p>			

[연구결과 보고서]

1. 연구결과 요약문

(한글) 딥러닝을 활용한 식품소비자 불만족과 요청사항 연구; 콜센터의 고객 질의-응답

(영문) A Study on Food Consumer Complaints and Requests Using Deep Learning

FMCG(Fast-Moving Consumer Goods)의 하나인 식음료는 회전율이 높고 트렌드에 민감하며 표출하는 소비자(고객)의 니즈가 확실한 제품이다. 따라서 고객의 니즈와 불만족을 이해하는 것이 중요하다. 고객의 니즈와 불만족 여부를 연구할 수 있는 좋은 대상은 콜센터(call-center)이다. 콜센터는 다양한 채널을 통해 고객을 이해하고 상호작용하기 위해 설계되었다. 최근 콜센터는 고객 에이전트가 우수한 고객 지원을 제공하기 위해 음성처리 기술 및 자연어 처리를 위한 딥러닝 기법을 활용하고 있다. 특히 자연어 처리(NLP; Natural Language Processing) 분야의 발전이 콜센터 플랫폼에 도입되어 혁신적인 발전을 도모하고 있다.

본 연구는 다음과 같은 연구목적을 가진다. 첫째, 콜센터에 접수된 다양한 요청사항을 확인하여 불만족을 가져오는 다양한 양상을 살펴보고, 어떠한 요소가 가장 빈번하게 고객 불만족을 가져오는지를 확인한다. 둘째, 텍스트 분석을 통해 고객의 경험과 불만족 사항들을 정형화된 구조로 목록화하고 분류한다. 딥러닝을 활용하여 고객의 요청사항을 효율적으로 분류하여 예측하는 모델을 구축한다. 셋째, 본 연구는 분류체계에 맞춰 소비자의 불만족과 요청사항을 이해하고 각각 다른 불만족 상황에 맞는 최적화된 대응 방안을 제공하는 서비스 모델을 개발한다.

연구목적에 맞춰, 본 연구는 딥러닝을 활용하여 세 가지 분석(버토픽을 활용한 토픽 모델링, koBERT 를 활용한 소비자 요청사항 예측, 트랜스포머를 활용한 챗봇 개발)을 진행한다. 콜센터(민원) 질의 응답 데이터셋은 민간기업과 공공기관의 콜센터(민원) 상담 내역을 기반으로 구축한 질의응답 학습 데이터셋을 이용하여 분석을 진행하였다. 특히, 상담사와 소비자(고객)의 질의 응답 자료를 집중적으로 활용하였다.

식품 관련 주요 문의 및 요청사항은 제품과 배송에 관련된 것이다. 버토픽을 통한 토픽모델링 분석결과 기초제품정보 및 품질 안정성(제품), 배송시간 및 지연(배송)에 관련된 문의가 주요 토픽임을 발견하였다. 소비자는 식음료 제품 관련하여 제품 품질과 배송에 집중적으로 관심이 있음을 확인하였다. 문의(불만족) 의도 분류 모델 구축 결과, 82%의 정확도를 가진 서비스 모델을 구현할 수 있었다. 효율적인 대화형 음성 응답(IVR) 시스템에 도움이 될 것이라 판단된다. 챗봇 구현 결과 적합한 응답을 제공할 수 있었다. 다만, 의도 분류 모델의 경우 정확도를 더욱 높여야 하는 과제와 챗봇의 경우 부적절한 응답을 개선해야 하는 지속적인 연구 과제가 남아 있다.

II. 연구과제 연구결과

제1장 최종 연구개발 목표

1.1 연구과제의 목표

1.1.1 연구배경

FMCG(Fast-Moving Consumer Goods)의 하나인 식음료는 회전율이 높고 트렌드에 민감하며 표출하는 소비자(고객)의 니즈가 확실한 제품이다. 따라서, 식음료 산업에서는 소비자가 요구하는 것이 무엇인지 빠르고 정확하게 파악하는 것이 중요하다. 또한 소비자가 만족하지 않은 경우 불만족의 원인을 확인하고 조사하는 것이 필요하다. 기존의 연구는 식품 소비경험자의 만족 여부를 설문조사를 통해 소비자에게 직접적으로 묻거나 콜센터(call-center) 혹은 컨택트 센터(contact-center, 이하 콜센터로 통일)를 통해 불만족 사항을 접수하여 확인하는 것이 주된 방식이었다. 과거에는 소비자의 요구사항을 표적집단 면접법(FGI; Focus group interview) 같은 질적연구방법론이나 설문조사를 통해 확인하였다. 설문조사의 경우 편향성(Bias)이 존재하고 면접법의 경우 사람이 직접 만족, 불만족을 평가해야 한다는 한계점이 있었다.

콜센터는 다양한 채널(전화, 이메일, 웹 양식 및 온라인 라이브 채팅)을 통해 고객을 이해하고 상호작용하기 위해 설계되었다. 콜센터는 다양한 고객의 목소리를 듣고 그에 맞는 서비스를 제공하여 고객 경험을 향상시키는 역할을 한다. 콜센터의 경우는 소비자의 요청사항을 자동화된 방식으로 데이터로 전환한다. 다음의 예시(소비자와 담당자의 고객 상호작용)는 소비자가 불만족 혹은 요청사항을 표현하는 기록의 일부이다.

*[소비자] ‘배송이 지연되는 것을 빨리 처리해주세요. 저희가 잘못 주문한 거
도 아니고 판매자 분실 실수인데 계속 기다려야 하나요?’*
[콜센터 담당자] ‘확인하여 빠른 조치하도록 하겠습니다.’

위의 상담 사례는 판매자의 특정 식품의 배송 오류에 따른 소비자의 불만족 접수 상황이다. 소비자는 불만족을 직접 표현하고 있으며, 콜센터 담당자는 소비자(고객)의 불만족에 대해 적절하게 잘 대응하고 있다. 콜센터는 고객관계관리(CRM: Customer Relationship Management) 관점에서 고객의 불만족을 효과적으로 이해하고 관리하는 중요한 부서이다. 고객의 불만족 사항을 개선하여 만족한 상황으로 만드는 것은 개별 고객의 이탈율(churn rate)을 줄이고, 고객과의 관계를 장기적으로 구축하며, 긍정적인 브랜드 이미지를 축적한다. 또한, 만족한 고객의 경우, 기업 서비스를 칭찬의 형태로 주변에 퍼트리는 매개체 역할을 한다. 따라서 소비자의 불만족 요인을 파악하는 효율적인 방법 중 하나는 직접적으로 소비자들의 목소리를 콜센터나 무인상점을 통해 고객의 소리를 녹음하고 기록하는 것이다.

코로나 19 대유행 시기 동안 콜센터의 중요성은 더욱 강조되었다. 코로나로 인한 비대면 관계가 심화되었을 동안 지불 연기, 예약 취소, 재고 조회, 상품 배송 현황 조회 등의 다양한 커머스 불만족 상황이 발생하였고, 이로 인한 고객 문의는 증가하였다. 콜센터는 고객 요구 증가와 축적되는 거대한 데이터양으로 인해 음성을 기록하고 분석하는데 여러 가지 기술적인 도전에 직면하고 있으며, 비즈니스 측면에서 활용도가 더욱 커지고 있다. 최근 딥러닝 기술(음성처리, 자연어 처리 등) 및 머신러닝 기술을 통합한 플랫폼(셀프서비스 음성포털(self-service voice portals) 혹은 챗봇)이 고객 서비스 향상을 위해 다양한 분야에서 도입되고 있다.

1.1.2. 연구목적

최근 콜센터는 고객 에이전트가 우수한 고객 지원을 제공하기 위해 음성처리 기술 및 자연어 처리를 위한 딥러닝 기법을 활용하고 있다. 앞 장의 불만족 사례와 같이 많은 음성녹음 파일들이 콜센터의 데이터베이스에 저장된다. 상담을 완료한 후 콜센터 담당자는 통화 내용에서 소비자의 불만을 적절한 형태로 기록하고 판단하여 ‘교환[반품]환불_시간_요청’의 항목으로 분류한다. 소비자의 불만과 의견은 과거의 조사 방식인 설문지의 응답과 달리 녹음이라는 방법으로 음성(비정형 데이터)으로 실시간으로 저장되고 있다. 따라서, 고객의 경험을 다양한 비즈니스 전략으로 전환하기 위해서는 전통적인 마케팅 조사기법 대신 음성인식, 음성처리와 자연어 처리라는 인공지능(딥러닝) 방법론이 요구된다. 이는 소비자의 목소리(음성)을 자연어로 번역한 후 분석하는 방법으로 기존 설문조사의 한계를 극복하고 있다. 비정형 자료(음성, 자연어)가 실시간으로 축적되면서 식품소비자 불만족과 요청사항을 분석하기 위해 딥러닝을 활용한 콜센터 플랫폼이 도입되었지만 여전히 경영학 분야에서의 연구는 부족한 실정이다.

특히 자연어 처리(NLP; Natural Language Processing) 분야의 발전이 콜센터 플랫폼에 도입되어 혁신적인 발전을 도모하고 있다. 자연어 처리는 언어를 인간과 유사한 방식으로 이해하기 위해 데이터 과학과 언어학을 결합하는 학문이며, 최근 다양한 딥러닝 기법을 활용하여 빠르게 진화하고 있다. 따라서 기업의 콜센터는 전통적인 대화형 음성 응답(IVR; Interactive Voice Response) 시스템에서 NLP 기술로 전환해왔다. NLP의 도입은 고객이 매 불편함을 더 잘 이해하고, 따라서 더 나은 고객 경험을 바탕으로 하는 서비스를 제공할 수 있다. 또한 고객의 요구를 더 잘 이해할 수 있다.

본 연구는 다음과 같은 연구목적을 가진다. 첫째, 콜센터에 접수된 다양한 요청사항을 확인하여 불만족을 가져오는 다양한 양상을 살펴보고, 어떠한 요소가 가장 빈번하게 고객 불만족을 가져오는지를 확인하려고 한다. 둘째, 텍스트 분석을 통해 고객의 경험과 불만족 사항들을 정형화된 구조로 목록화하고 분류하려고 한다. 딥러닝을 활용하여 고객의 요청사항을 효율적으로 분류하여 예측하는 모델을 구축하려고 한다. 셋째, 본 연구는 분류체계에 맞춰 소비자의 불만족과 요청사항을 이해하고 각각 다른 불만족 상황에 맞는 최적화된 대응 방안을 제공하는 서비스

모델을 개발하려고 한다. 소비자의 생각을 예측하고 적절하게 대응하는 서비스 모델을 개발하는 것은 미래 식품 분야의 신성장 동력을 되찾는 데 도움이 될 것이다. 최종적으로는 챗봇에 기초가 되는 자동화된 맞춤형 대화모델을 개발하려고 한다. 딥러닝을 활용한 챗봇 모델을 구축하고, 적합한 서비스 모델을 구축하는 것이 연구의 목적이다.

1.1.3. 연구범위

연구목적에 맞춰, 본 연구는 딥러닝을 활용하여 세 가지 분석을 진행한다. 첫째, 콜센터에 접수되는 다양한 소비자의 의도를 토픽모델링(LDA 와 버토픽)으로 분석하고, 각 주제에 자주 등장하는 내용을 정리한다. 둘째, 소비자의 요청사항을 딥러닝을 활용하여 불만족 요인으로 분류하고, 의도를 예측하는 모델을 구축한다. 셋째, 불만족 요소를 해소하기 위한 최적의 반응을 생성하는 챗봇 모델을 구현한다.

본 연구는 다음과 같은 구조를 되어 있다. 2 장에서는 연구 내용 및 방법을 서술한다. 세 가지 분석에 적용되는 각 분석 방법론을 이론적으로 알아보고, 샘플 데이터에 적용해 본다. 3 장에서는 분석 결과를 제시한다. 4 장에서는 분석 결과를 해석하고, 그 의미를 살펴본다. 5 장에서는 연구 성과와 한계점을 언급한다. 6 장에서는 본 연구서가 참고한 다양한 참고문헌을 정리한다.

1.2 연구과제의 목표달성도와 기여도

앞서 언급한 것처럼 본 연구는 상호배타적이지 않은 세 가지 분석을 진행하였다. 연구 과제 종료 후, 2~3 개의 연구논문으로 출간하기 위해 진행 중이다. 첫 번째 연구, ‘버토픽을 이용한 소비자 요청사항 연구’(가칭)은 현재 LDA 와 버토픽을 활용한 토픽모델링을 소비자의 주된 여섯 가지 요청사항에 적용하였다. 5 개의 의도에서 유의미한 결과를 발견하였고, 논문으로 진행 중이다. 두 번째 연구, ‘트랜스포머를 활용한 소비자 불만족 사항 분석과 의도예측’(가칭)은 현재 트랜스포머를 활용하여 다중 클래스 분류 모델을 학습시켰다. 초매개변수(hyper-parameters)를 조정하며 학습 및 예측 결과를 발전시키고 있다. 또한 DistilBERT, RoBERTa 등의 최신 자연어 모델을 적용하여 성능이 가장 뛰어난 모델을 찾기 위해 계속 작업 중이다. 세 번째 연구, ‘콜센터 챗봇 연구’(가칭)은 논문으로 진행하기 위한 초기 단계이다. 문헌연구를 진행하면서, 소비자의 불만족을 완화할 수 있는 챗봇을 정밀하게 구현하기 위해 더 연구가 필요하다. 또한 텍스트 마이닝의 주된 분야인 감성분석(sensitive analysis) 연구를 추가하려고 노력 중이다.

콜센터 분야의 연구는 텍스트 마이닝 기법을 중심으로 한 공학적인 접근과 소비자 만족, 소비자 경험 등의 비즈니스 분야의 접근이 함께 이루어져야 한다. 기존의 연구들은 콜센터 분야의 공학적인 접근에 집중해 왔다. 이 연구의 가장 큰 기여 부분은 공학적인 분석을 통해 ‘불만족한 소비자 달래기’라는 경영학적 전략을 도출하려는 것이다.

1.3 국내외 기술개발 현황

1.3.1. 문서(텍스트)자료 분석기술

콜센터 분석에 있어 최근 IT 기술의 발달과 함께 축적된 비정형 데이터를 이용한 다양한 분석 방법이 많은 연구자와 실무자들의 관심을 끌고 있다. 대화형 챗봇으로 축적된 비정형 데이터의 대표인 문서(텍스트)자료, 녹음된 음성자료, 서비스 플랫폼의 사진(이미지) 자료, 동영상 자료 등이 수집되고 제공되고 있다. 전통적으로 콜센터의 문서(텍스트)자료는 텍스트 마이닝 기법으로 분석되었다. 텍스트 마이닝 기법 중 대표적인 방법은 토픽모델링(Topic Modeling)과 감성분석(sentiment analysis)이다.

토픽 모델링은 대규모 데이터셋에서 잠재 변수를 추출하는 통계 방법론이다. 텍스트 마이닝에서 토픽 모델링은 본문 내에서 주제를 찾아내는 방법론이며, 문서에 내재되어 있는 특정한 토픽을 찾아내는 데에 사용된다.¹ 주로 등장하는 빈도가 높은 단어들을 찾고 분류하여 문서의 토픽으로 제시한다. 예를 들어 새로운 한식 문화에 대한 텍스트를 토픽 모델링으로 분석한다고 가정하자. 그중 새로운 요리인 ‘비빔밥’이라는 단어가 문서 내에서 자주 등장한다는 것을 발견하였다. 이 단어는 연구자에게 중요한 단어로 간주되며, 토픽모델링 기법에 의해 ‘피자’, ‘파스타’ 등과 같이 이탈리아식 단어가 모여있는 토픽보다는, ‘김치’, ‘불고기’와 같이 한식과 관련된 단어들이 모여있는 토픽으로 분류되어 제시될 것이다. 토픽 모델링은 대규모의 텍스트 데이터에서 의미를 찾아내기에 용의하여, 검색엔진, 혹은 고객 민원 시스템 등에 활용된다.

잠재 디리클레 할당 (Latent Dirichlet Allocation)은 토픽 모델링의 대표적인 알고리즘이다.² 잠재 디리클레 할당 (Latent Dirichlet Allocation, 이하 LDA) 은 확률 기반의 알고리즘으로, 토픽 모델링에 있어 가장 많이 사용되는 방법론이다. LDA 는 단어가 특정 토픽에 출현할 확률과, 특정 토픽이 문서에 존재할 확률을 결합하여 토픽을 도출해 낸다.³ 최적화, 노이즈 민감성, 그리고 불안정성과 관련된 문제점이 있으며, 추출된 토픽을 해석하기 어렵다는 단점이 있다. 2018 년 딥러닝 기법 중 하나인 트랜스포머(transformer) 기반의 BERT 를 활용한 토픽 모델링인, 버토픽(BERTopic)이라는 새로운 토픽 모델링 기법이 등장했다. 버토픽(BERTopic)은 기존 토픽 모델링인 LDA 와 임베딩 방식에 차이를 두어 문맥을 고려하지 못하는 LDA 의 한계를 보완하는 등, 자연어 처리에 있어 향상된 성능 때문에 큰 관심을 받고 있다.⁴

¹ 토픽 모델링. (2019.03.03). <WikiDocs>. Available: <https://wikidocs.net/30707>

² Gallagher, R. J., Reing, K., Kale, D., and Ver Steeg, G. (2017). Anchored correlation explanation: topic modeling with minimal domain knowledge. Trans. Assoc. Comput. Linguist.

³ Blei, D.M.(2012), ‘Probabilistic topic models,’ Communications of the ACM, 55(4), 77-84.

⁴ Abuzayed, A. and Al-Khalifa, H. (2021). ‘BERT for Arabic topic modeling: An experimental study on BERTopic technique.’ Procedia Computer Science, Elsevier, Vol. 189, pp. 191-194, <https://doi.org/10.1016/j.procs.2021.05.096>.

감성 분석(sentiment analysis) 또한 텍스트 마이닝에서 인기 있는 방법론이다. 감성 분석(sentiment analysis)은 텍스트에 나타난 사람들의 태도, 의견, 성향과 같은 주관적인 데이터를 분석하는 자연어 처리기술이다. 주로 텍스트에 나타난 긍정적 또는 부정적 감정과 관련된 내용을 측정한다. 감정 지향적인 단어는 소비자의 구매 행동에 중요한 영향을 미치는 것으로 알려져 있다. 개인적이고 사적인 대화에서 많이 발견되는 감정적인 단어의 사용 정도를 파악함으로써 제품의 타이틀과 제품에 대한 설명이 얼마나 감정적인가의 정도를 측정할 수 있다. 제품 상세 설명이 감성적(affective)인가 비감성적(formal)인가를 판단하기 위해 LIWC (Linguistic Inquiry & Word Count) 모델을 사용하기도 한다. LIWC 는 텍스트에 표현된 인간 감정의 다양한 측면을 연구하기 위한 효율적이고 효과적인 텍스트 분석 응용 프로그램이다. LIWC 를 이용한 방법론은 온라인 블로그, 온라인 인스턴트 메시징, 신문 기사, 그리고 전자상거래 기업의 온라인 리뷰, 콜센터의 불만족 요청 자료 등의 다양한 텍스트를 분석하는 데 적용된 바 있다. 최근 딥러닝 기법인 RNN(Recurrent Neural Network), LSTM(Long Short-Term Memory) 모델, GRU(Gated recurrent unit) 모델, 트랜스포머(Transformer) 등을 사용하여 감성 분석의 정확도를 높일 수 있다는 것이 보고되었다.

1.3.2. 이미지(동영상) 자료 분석기술

이미지 분석을 위해서는 합성곱 신경망(CNN; Convolutional Neural Network), 미적 점수 평가를 위한 신경 이미지 평가(Neural Image Assessment, 이하 NIMA) 등의 딥러닝 기법을 활용한다. 합성곱 신경망(CNN)은 딥러닝 기법의 하나로 일반적으로 시각적 이미지를 분류하는 데 쓰이는 인공 신경망의 한 종류이다. CNN 은 크게 합성곱 계층(convolutional layer), 풀링 계층(pooling layer), 완전연결계층으로 구성되는 깊은 신경망이다. 합성곱 신경망을 통해 제품 이미지가 감성적인지 비감성적인지 분류할 수 있다. NIMA 는 CNN 모델을 기반으로 인공지능이 이미지의 기술적(technical) 그리고 심미적(aesthetic) 품질을 측정, 평가하는 기법이다. NIMA 는 이미지에 대해 1 점에서부터 10 점까지의 척도로 미적 평가를 하며, 10 점은 심미적으로 최고인 상태를 의미한다. NIMA 가 평가한 미적 평가 수치는 인간이 동일한 이미지를 보고 평가하는 것과 큰 차이가 없다는 장점을 가진다.

1.3.3. 음성(텍스트)자료 분석기술

콜센터에 활용 가능한 음성 인식 분야로는 지능형 가상 비서(Intelligent Virtual Assistance), 질의응답기술(Question & Answer), 음성인식기술 등이 있고 빠른 속도로 발전하고 있다. 지능형 가상비서는 음성 인식 기반 지능형 가상비서나 텍스트 기반의 챗봇이 콜센터에 적용될 수 있는 기술 분야이다. 핵심 기능은 사용자의 의도를 파악하여 적절한 기능을 수행하거나 응답을 생성할 수 있게 만드는 것이다. 딥러닝의 의미추론 분야의 기술이 필요하다. 질의응답 기술은

콜센터에서 활용될 수 있는 중요한 자연어 처리 딥러닝 분야이다. 질의응답 기술을 처리하기 위해서는 질의유형 분류, 의미추론, 적절한 응답의 선택 등의 순차적인 기술이 필요하다. 이 분야의 기술들은 챗봇을 구현하는 데 아주 중요하다.

음성인식 기술은 음성을 문자로 변환(Speech to Text)하는 기술과 문자를 음성으로 변환(Text to Speech)하는 음성합성 기술 등 다양한 알고리즘이 존재한다. 전통적인 음성인식 기술은 음향모델(음성 신호를 분석해서 음절과 어절을 생성)과 언어모델(생성된 어절을 통계적으로 보정)로 구성이 된다. 전통적인 음성 인식 시스템에서는 은닉 마르코프 모델(HMM; Hidden Markov Model)과 가우시안 혼합 모델(Gaussian Mixture Model, 이하 GMM)을 많이 사용하였다. 최근에는 딥러닝 기법을 사용하여 기존의 GMM 에 비해 우수한 성능을 가진 음성인식 기술들이 개발되었다. 위와 같이 자연어 처리 기술, 이미지(영상) 처리 기술, 음성처리 기술을 딥러닝과 함께 급속도로 빠르게 발전하고 있다. 하지만, 알고리즘과 기술적인 발전에도 불구하고 여전히 비즈니스 생태계에서의 활용도는 높지 않은 실정이다. 소비자의 요구사항과 반응(예를 들어, 만족과 불만족)을 딥러닝을 활용하여 이해하려는 노력은 비즈니스 분야에서는 매우 중요한 융합연구이지만 여전히 부족한 실정이다.

제2장 최종 연구 내용 및 방법

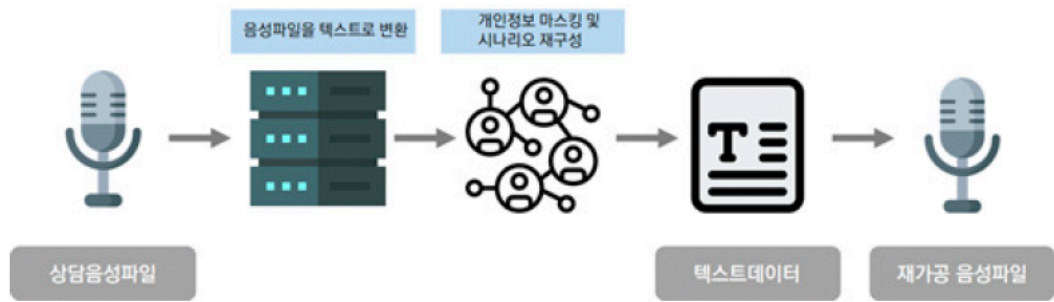
2.1. 데이터

2.1.1. 샘플 데이터 셋 개요

콜센터(민원) 질의 응답 데이터셋은 민간기업과 공공기관의 콜센터(민원) 상담 내역을 활용하여 구축한 질의응답 학습 데이터셋이다. 이 데이터셋은 상담사와 고객 간의 질의-응답 110 만쌍, 이를 녹취한 음성데이터 440 시간으로 구성되어 있다. 본 연구에서는 데이터셋에서 ‘식품’ 카테고리에 해당하는 434,313 행을 추출하여 분석을 진행하였다.

2.1.2. 데이터셋의 구성

본 데이터셋은 음성 데이터를 재가공한 텍스트데이터 110 만 대화 쌍과 재가공한 텍스트 데이터를 녹음한 음성데이터 2 가지 형태로 구성되어 있다. 상담 건마다 상담 시간의 차이가 있기 때문에 대화 쌍을 기준으로 데이터를 구성했으며, 카테고리별로 데이터셋이 설계되어 있다. 따라서 본 데이터셋의 ‘식품’ 카테고리에 해당하는 데이터를 분석에 활용하여 올바른 학습 모델을 구축한다.



<그림 1> 질의-응답 데이터 자료 추출과정⁵

2.1.3. 데이터의 구조 및 예시

본 데이터는 <표 1>과 같이 다음과 같은 변수들로 구성되어 있다.

항목		설명	예시
도메인		대분류	주문, 결제, 배송 등
카테고리		중분류	주문확인, 주문처리, 단순배송문의 등
대화셋 일련번호		데이터건 별 식별번호	데이터건 별 1,2,3..
화자		상담사와 고객을 분리하는 번호	0 : 상담사, 1 : 고객
문장번호		질의, 응답 한 문장 당 부여된 번호	문장별 1,2,3..
의도 정보	Main	고객의도	방송상품 주문요청
	Sub	상담사의도	고객주소등록
QA		질의-응답 구분	Q:질의, A:응답
원본	Main Q	고객 질문	네 방송 보고 있는데 주문하려고요
	Sub Q	상담사 질문	고객님 상세 주소 알려주시겠어요?
	User Answer	고객 응답	네 전화번호는 000-0000-0000
	System Answer	상담사 응답	네 등록해드리겠습니다.
개체명		문장 중 명사 단어들을 '/'로 분리	주문, 삼성카드, 현금 영수증
용어사전		개체명의 유사 및 동의어	성함/성명/이름. 신청/주문
지식베이스		개체명이 해당 문장에서 쓰이는 의미를 기술	엘에이 갈비/상품명, 삼성카드/카드명

<표 1> 질의-응답 데이터 자료 구조

<그림 2>는 식품 카테고리에 기록된 상담 내용의 구조화된 데이터의 예시이다. 발화자가 고객(소비자)인지 상담사인지를 확인할 수 있고, 질문인지 응답인지도

⁵ 포티투마루, 콜센터(민원) 업무의 효율화를 위해 AI 기술을 활용한 ICC(Intelligent Contact Center) 관련 기술 개발에 활용할 수 있는 상담 내역 질의응답 학습데이터셋 구축 (AI-Hub, 2023)

확인할 수 있다. 식별자에 따라 발화문 원문과 응답문 원문을 확인할 수 있다. 상담사의 분류에 따라 상담전화의 요청사항이 무엇인지 기록되었다.

IDX	발화자	발화문	카테고리	QA번호	QA여부	감성	인텐트 (대)	인텐트 (중)	인텐트 (소)	상담번호	상담내순번
1	c	답답 2만원 이상을 사면 무료 배송으로 하는데 여기가 죽도 추가로 몇 개 더 주문해도 추가 배송비	식품	46175	q	m	배송	비용	질문	46175	1
2	s	백스에 램프가 되지 않을 수도 있어 정확한 답변 드리지 못하는 점 양해 부탁드립니다.	식품	46175	a	m	배송	비용	질문	46175	2
3	c	헤마로 기존 6개 이상이고 배송할 기준으로는 50개 이상인데 헤마로 케어존 1통과 묶음밥 10통	식품	40543	q	m	배송	비용	질문	40543	1
4	s	일단 두 제품이 같이 담긴다면 최소 주문 부피인 6개 이상은 시스템 상 자동회차가 됩니다.	식품	40543	a	m	배송	비용	질문	40543	2
5	c	마트 원대이는 무료 배송이라고 되었는데 왜 결제할 하려고 하니까 배송비 3000원이 붙는 건가요	식품	15426	q	m	배송	비용	질문	15426	1
6	s	1KG 5 팩 이 상 무료배송 상품입니다.	식품	15426	a	m	배송	비용	질문	15426	2
7	c	제주도 추가 배송료 있나요?	식품	226944	q	m	배송	비용	질문	226944	1
8	s	문의해주셔서 감사해요	식품	226944	a	m	배송	비용	질문	226944	2
9	c	물건이 오지도 않았는데 취소하게 되면 3천원이 빠지더라도 요 반품 택배사원이 오는 것도 아닌데	식품	229560	q	n	배송	비용	질문	229560	1
10	s	운송장 발행되어 택배사에서 발송하면 반품 배송비가 발생해요.	식품	229560	a	m	배송	비용	질문	229560	2
11	c	배송비 문의 구매비와 배송료 8000원만 거내면 되는 건가요?	식품	70853	q	m	배송	비용	질문	70853	1
12	s	이 전문의 끝에 안내해드렸으니 확인해주시기 바랍니다. 공공하산 사항은 현재는 문의주시기 바랍니다	식품	70853	a	m	배송	비용	질문	70853	2
13	c	무료 배송 전에 증자 김치같이 배송받으려 하니 배송비가 추가되네요. 어떻게 해야 하나요?	식품	33379	q	m	배송	비용	질문	33379	1
14	s	무료 배송 상품과 유료배송 상품을 같이 구매한다고 해서 유료배송 상품이 무료 배송이 되는 게 어	식품	33379	a	m	배송	비용	질문	33379	2
15	c	제주도 추가 배송비 있나요?	식품	261491	q	m	배송	비용	질문	261491	1
16	s	네 추가 배송비는 없습니다.	식품	261491	a	m	배송	비용	질문	261491	2
17	c	제주도 추가 비용 얼마인지 알 수 있을까요?	식품	198157	q	m	배송	비용	질문	198157	1
18	s	무게가 있다보니 4000원이 나오네요. 도울 되시길 바랍니다.	식품	198157	a	m	배송	비용	질문	198157	2
19	c	배송비가 무료 내로 배송비가 무료인데, 두 개나 세 개 구매하면, 더 할인 안되나요?	식품	15690	q	m	배송	비용	질문	15690	1
20	s	불수 구매 시에도 할인인 적용되지 않습니다.	식품	15690	a	m	배송	비용	질문	15690	2
21	c	무료 배송인 제품이랑 같이 구매하는 데도 배송비 또 내야 하나요?	식품	154541	q	m	배송	비용	질문	154541	1
22	s	무료 배송 상품은 현재 묶음배송이 되지 않는 단일 제품입니다. 무료 배송 제품 이외 상품을 같이	식품	154541	a	m	배송	비용	질문	154541	2
23	c	배송비 있나요?	식품	55029	q	m	배송	비용	질문	55029	1
24	s	플루배리 배송비는 3000원 부과됩니다.	식품	55029	a	m	배송	비용	질문	55029	2
25	c	제주도 추가 배송비있나요?	식품	266348	q	m	배송	비용	질문	266348	1
26	s	제주도 추가 배송비 없을 안 내드려요.	식품	266348	a	m	배송	비용	질문	266348	2
27	c	배송비요 어린이 흥산도 같이 주문했는데 무료로 배송 안 되나요?	식품	198174	q	m	배송	비용	질문	198174	1
28	s	무료로 배송됩니다. 혹시 배송비 결제되면 알려주세요.	식품	198174	a	m	배송	비용	질문	198174	2
29	c	제주도 추가 배송비 있나요?	식품	228904	q	m	배송	비용	질문	228904	1
30	s	넌 제주의 경우 기본 배송료는 무료 배송되며 추가 운임은 3000원 발생이 되나선 지역의 경우 더	식품	228904	a	m	배송	비용	질문	228904	2
31	c	수입과자라도 무료 배송이 적용되지 않는데 모찌초코렛 사면 무료 배송이 아니가요?	식품	28331	q	m	배송	비용	질문	28331	1
32	s	상품에 기본 배송비는 2500원이 적용됩니다. 추가 구성품은 함께 사시면 별도로 배송비를 안 내고	식품	28331	a	m	배송	비용	질문	28331	2
33	c	무임차랑 같이 주문할려니 배송비가 5천원이 드네요 묶음 배송 메뉴에도 무임차는 없고 판매자가	식품	126278	q	m	배송	비용	질문	126278	1
34	s	묶음 배송 설정에서 잘못되어 있는 것 같은데 묶음 배송 가능으로 처리해 놓았습니다.	식품	126278	a	m	배송	비용	질문	126278	2
35	c	김치와 들깨장을 같이 주문하려는 대것집지는 무배고들깨장은 배송비가 붙어요. 둘이 같이 하면	식품	36837	q	m	배송	비용	질문	36837	1

<그림 2> 식품 카테고리 질의-응답 데이터 예시

2.2. 버토픽을 활용한 토픽모델링

2.2.1. 트랜스포머(Transformer)와 버트(BERT)

트랜스포머(Transformer)는 2017 년 구글이 발표한 논문인 ‘Attention is all you need’에서 처음 등장한 딥러닝 모델이다. 단어나 문장과 같은 입력 데이터에서 중요한 정보를 추출(인코더)하고 출력 데이터(디코더)로 번역을 진행하거나 새로운 문장을 생성하는 등의 다양한 작업을 진행할 수 있는 딥러닝 모델이다. 기존의 seq2seq 의 구조인 인코더-디코더를 따르면서도, 어텐션(Attention) 만으로 구현한 모델이다. 트랜스포머 모델은 순환신경망(Recurrent Neural Network, 이하 RNN)을 사용하지 않고 셀프-어텐션(Self-Attention) 메커니즘을 활용하여, 인코더-디코더 구조를 설계하였음에도 번역 성능에서도 RNN 보다 우수한 성능을 보여주고 있다. 자연어 처리 분야, 음성처리 분야, 이미지처리 분야에서 최근 많이 활용되며, 대용량의 데이터를 학습하여 번역, 요약, 질문 응답 등의 다양한 작업에서 높은 성능을 보인다.

버트(BERT)와 GPT(Generative Pre-Trained Transformer)는 트랜스포머 모델을 기반으로 한 대표적인 모델이다. BERT(Bidirectional Encoder Representations from Transformers)는 양방향 트랜스포머 모델을 기반으로 한 사전 학습(pre-training) 모델이다.⁶ 트랜스포머 모델이 셀프-어텐션을 활용한 딥러닝의 구조를 설계하는 데 중점을 두었다면, BERT 는 주로 사전학습되어 공개된 언어모델의 활용과 자연어 임베딩에 중점을 두었다. BERT 는 대용량의 텍스트 데이터를 활용하여 사전 학습을 수행하였기 때문에, 다양한 다른 분야의 자연어 처리 문제에서 매우 우수한 성능을

6 Devlin, Jacob, et al. ‘Bert: Pre-training of deep bidirectional transformers for language understanding.’ NAACL 2019 (arxiv 2018.10)

보인다. GPT(Generative Pre-trained Transformer)는 단방향 Transformer 모델을 기반으로 한 사전 학습 모델이며, 결과를 문장으로 ‘생성(Generative)’하는 생성 AI 이다. 2022 년 소개된 OpenAI 사의 대화형 AI(ChatGPT⁷)는 기계번역, 요약, 자연어 생성 문제 등에서 우수한 성능을 보여주고 있다.

2.2.2. LDA 와 버토픽의 차이

1 장에서는 LDA 를 간략하게 설명하였다. 2 장에서는 LDA 와 용한 버토픽(BERTopic)의 차이를 간략하지만 구체적으로 알아보려고 한다.

잠재 디리클레 할당 (Latent Dirichlet Allocation, LDA)은 컴퓨터가 자연어를 이해할 수 있게 하는 벡터화 과정에서 BoW(Bag of Words)를 활용한다. 다만, BoW 는 단어의 순서는 고려하지 않은 채, 출현 빈도에 기반하여 벡터화한다. 빈도 기반인 BoW 의 특성은 단어의 위치 정보를 제공할 수 없기에, LDA 는 문맥을 반영하지 못한다는 한계를 지닌다. 이는 특히 동음이의어 처리에 어렵다. 동음이의어는 같은 단어라도 앞뒤에 오는 단어에 따라 그 의미가 바뀌기에, 어디에 위치하는지가 중요하다(즉, 문맥이 중요하다). 예를 들어 우리말의 ‘사과’는 ‘굴’, ‘포도’와 한 문장에서 쓰일 때와 ‘잘못’, ‘용서’와 함께 쓰일 때의 의미가 다르다. 하지만, BoW 는 단어 위치에 대한 정보를 제공하지 않기 때문에, 이러한 문맥에 따른 차이를 고려할 수 없다.⁸ 즉 문맥을 고려하지 못하는 한계를 가진다. 버토픽은 이러한 한계를 보완하며 성능까지 훨씬 우수하기 때문에 최근 각광을 받고 있다.

버토픽(BERTopic)은 2018 년 구글에서 공개한 BERT(Bidirectional Encoder Representations from Transformers)를 활용한 토픽 모델이다. BERT 는 앞서 언급한 것과 같이 트랜스포머(transformer) 모델을 기반으로 사전 훈련(Pre-training)된 딥러닝 모델이다.⁹ 버토픽(BERTopic)은 ‘문서 임베딩-문서 클러스터링-토픽 제시’의 세 가지 단계를 통해 구현된다. 버토픽(BERTopic)은 임베딩 방법으로 Sentence-BERT (SBERT)를 사용한다. SBERT 는 사전 학습된 모델을 통해 문장 혹은 단락 단위로 벡터화한다. UMAP 을 활용하여, 임베딩한 문서의 차원을 축소하고, HDBSCAN 을 활용하여 클러스터링한다. UMAP 는 PCA 와 t-SNE 에 비해 차원 축소 시에 데이터의 특성을 잘 보존하는 데에 탁월하다. 버토픽은 토픽 표현 시에 클래스 기반의 TF-IDF 를 활용한다. 이는 개별 문서가 아닌, 클래스 내에서의 단어의 중요성을 구별하여 중요성을 계산한다. 각 단어의 중요성은 식 (1)과 같이 정의한다.¹⁰

7 미국의 AI 연구재단 OpenAI(오픈에이아이)가 2022년 11월 공개한 초거대 언어모델 GPT-3.5 기반 대화형 인공지능 챗봇이다.

8 Bag of words. (2019.03.03). <WikiDocs>. Available : <https://wikidocs.net/22650>.

9 버트(Bidirectional Encoder Representations from Transformers, BERT). (2023.02.04). <WikiDocs>. Available : <https://wikidocs.net/115055>

10 Maarten Grootendorst. (2022.03.11). BERTopic: Neural topic modeling with a class-based TF-IDF procedure

$$W_{t,c} = t, f_{t,c} \cdot \log \left(1 + \frac{A}{tf_t} \right) \quad \text{식 (1)}$$

식 (1)에서 t 는 특정 단어(term)를, c 는 단어가 속한 클래스(class)를 의미한다. Tf_t (term frequency)는 특정 단어가 등장하는 개수를 $tf_{t,c}$ 는 특정클래스에 속한 특정 단어가 등장하는 개수를 의미한다. 버토픽(BERTopic)의 기반인 버트(BERT)는 트랜스포머(transformer)를 활용하여 문맥을 반영하지 못하는 기존 텍스트 마이닝 모델의 한계를 보완한다. 기존 모델은 순차적으로 앞에 단어를 통해 뒤에 단어를 예측하는 단방향성을 따른다. 이러한 단방향성은 문맥을 고려하지 않는다는 한계를 지닌다. 버트(BERT)는 트랜스포머(transformer)를 통해 양방향성을 구현하고, 포지션 임베딩 (Position Embedding)을 활용하여 단어의 위치정보를 제공한다. 양방향성을 지니고 단어의 위치 정보를 제공하는 버트(BERT)는 기존의 텍스트 마이닝 모델에 비해 문장의 맥락을 고려하는 성능이 뛰어나다.^{11 12}

즉, 버트를 활용한 토픽 모델링인 버토픽은 기존의 토픽의 한계였던 문맥 정보 손실을 보완한다. 또한, 사전 훈련된 트랜스포머(transformer)를 파인 튜닝(Fine-tuning)을 하여 활용하기 때문에 더욱 높은 성능을 보여준다.

2.2.3. 버토픽 활용 데이터와 기술통계량

다음은 버토픽 모델을 구현하기 위해 사용한 샘플데이터의 예시이다. 고객의 불만족 요소와 요청사항을 이해하기 위해 콜센터 담당자의 응답문을 제외하고, 소비자의 발화문에 집중한다. 또한 미리 정의된 발화문의 의도를 중심으로 발화문을 이해하도록 한다.

발화문 인텐트 (대)		
0	컵밥 2만원 이상을 사면 무료 배송으로 아는데 여기가 죽도 추가로 몇 개 더 주문해...	배송
1	박스에 합포가 되지 않을 수도 있어 정확한 답변 드리지 못하는 점 양해 부탁드립니다.	배송
2	해마로 기준 6개 이상이고 볶음밥 기준으로는 50개 이상인데 해마로 케이준 1봉과 ...	배송
3	일단 두 제품이 같이 담기면 최소 수량 부과인 6개 이상은 시스템 상 자동부과가 됩니다.	배송
4	마트 원데이는 무료 배송이라고 되었는데 왜 결제를 하려고 하니까 배송비 3000원이...	배송

<그림 3> 발화문과 요청의도 예시


배송 의도의 분류결과 <표 2>와 같은 결과를 얻었다. 총 9 개의 인텐트 중 하위 4 개의 의도 ‘교환|반품|환불’과, ‘웹사이트’, ‘AS’, ‘멤버십’을 기타 그룹으로 묶어서

11 Kukushkin, K., Ryabov, Y., & Borovkov, A. (2022) Digital twins: A systematic literature review based on data analysis and topic modeling. Data, 7(12), 173.

12 버토픽(BERTopic). (2022.11.14). <WikiDocs>. Available: <https://wikidocs.net/162076>

구분하였다. ‘제품’, ‘배송’, ‘행사’, ‘포장’, ‘결제’, ‘기타’ 총 6 개의 의도(대분류)로 구분하여 토픽 모델링을 진행하였다. <표 2>에서 보면, 의도(대분류)에서 ‘제품’은 전체 요청의도의 47.86%, ‘배송’은 42.38%의 비중을 차지하고 있다. 식품 콜센터의 90%에 대한 문의는 제품 (품질, 사용법 등) 혹은 배송과 관련되어 있다.

순위	요청 의도	발화문 수	구성비율
1	제품	207,857	47.86%
2	배송	184,069	42.38%
3	행사	14,384	3.31%
4	기타	11,376	2.62%
5	포장	8,704	2.00%
6	결제	7,922	1.82%
전체		434,312	100%



<표 2> 요청의도 분류구성

<그림 4> 요청의도수(대분류) 분포

2.2.4. 버토픽 분석 절차

본 연구에서는 LDA와 버토픽(BERTopic)을 구현해 보고, 콜센터 데이터를 활용하여 두 방법론의 성능 비교해 보고자 한다. 또한 토픽 모델링을 활용하여 고객들의 주요 민원(요청) 사항, 불만족 요소를 확인한다.

1) 데이터 수집

AI Hub에서 제공하는 민원(콜센터) 질의-응답 데이터를 활용하였다. 이는 2022.01.26년 개방된 데이터로, 110만 쌍의 질의응답을 녹취한 음성 데이터를 텍스트 데이터로 가공한 것이다. 이 중 민간기업의 식품 카테고리 데이터를 분석에 활용하였다.

2) 데이터 전처리

총 9개의 발화문 중 비교적 개수가 적은 ‘교환|반품|환불’과, ‘웹사이트’, ‘AS’, ‘멤버십’ 4개의 의도 분류를 기타로 통합하여, ‘제품’, ‘배송’, ‘행사’, ‘포장’, ‘결제’, ‘기타’ 총 6개의 요청의도로 구별하였다. 이후 한국어 불용어 목록과 상위 빈출 단어를 확인하여 총 963개의 불용어를 처리하였다.

3) 토픽 모델링

LDA와 버토픽(BERTopic), 두 토픽 모델링을 수행하고 그 결과를 비교한다. LDA와 버토픽 명사만을 추출하여, 동일한 개수의 토픽을 할당하고, 토픽에 따른 주제어를 제시하였다. BERTopic 분석 시에 한국어 포함 100가지 언어를 지원하는 sentence-BERT 기반 모델인 ‘xlm-r-100langs-bert-base-nli-stsb-mean-tokens’를 활용하여 임베딩했다.

2.3. 트랜스포머를 활용한 다중의도분류 모델

2.3.1. 머신러닝과 딥러닝을 활용한 다중클래스 분류

다중 클래스 분류(Multiclass Classification)를 이해하기 위해서는, 먼저 이진 분류(Binary Classification)을 이해하여야 한다. 이진 분류는 말 그대로 2 가지 분류 선택지가 존재하고, 알고리즘에 의해 2 가지 집단 중 하나로 분류하는 과정을 의미한다. 메일이 정상메일인지 스팸메일인지 판독 분류하는 작업이 머신러닝에서 대표적인 가장 이진 분류의 예시이다. 로지스틱 회귀분석(Logistic Regression)이 가장 대표적인 회귀분석 방법론이며, 때로는 선형 분류(Linear Classifier) 혹은 비선형 분류(Non-linear Classifier)를 쓰기도 한다.


다중 클래스 분류(Multiclass Classification)는 이진 분류의 확장형이다. 분류집단이 0 ~ k 개까지 존재하고, 이 중 한 가지 집단으로 분류하는 것이 다중 클래스 분류이다. 동물 이미지를 ‘개’, ‘고양이’, ‘소’ 등 여러 동물 종류 중 하나로 분류하는 경우가 대표적인 다중 클래스 분류의 예시이다. 머신러닝에서는 결정 트리, 랜덤 포레스트, 서포트 벡터 머신(SVM), 인공 신경망 등이 많이 활용되는 알고리즘이다. 최근 딥러닝에서 가장 각광받는 트랜스포머 모델로 이진 분류와 다중 클래스 분류는 딥러닝의 트랜스포머 모델을 활용하면서 정확도가 크게 개선되었다.

이진 분류는 최종단계의 활성화 함수(목적함수)로 시그모이드(Sigmoid) 함수를 사용하고, 다중 클래스 분류의 경우 소프트맥스(softmax) 함수를 사용한다. 트랜스포머를 활용한 다중 클래스 분류 활성화 함수가 다른 것은 아니다. 어텐션을 이용한 트랜스포머 층을 인코더에 포함한다.

Transformer 모델은 RNN 대신 self-attention 메커니즘을 도입하여 각 단어의 상대적인 중요성을 동적으로 학습할 수 있다. 어텐션 메커니즘은 인코더와 디코더 간의 정보 교환을 원활하게 처리하며, 긴 문장을 처리할 때 각 위치의 단어에 적절한 가중치를 부여하여 정보 손실을 최소화한다.¹³ 인코더는 입력 시퀀스를 받아 self-attention 을 적용하고, 그 결과를 최종적으로 소프트맥스 함수를 통해 각 분류집단에 해당할 확률을 구한다(모든 클래스 확률의 합은 1 이 되어야 한다). 가장 큰 확률값을 가지는 집단이 최종적으로 분류모델의 예측값이 된다.

<그림 5> 는 트랜스포머 모델을 기존의 인코더-디코더 구조에서 이해한 것이다. 인코더의 각 층에 어텐션을 계산하는 층이 존재하고 있으며, Multi-head attention 은 각 입력 데이터(단어 혹은 문장, 토큰화)의 상대적인 중요성을 계산하는 메커니즘이다. 문맥의 위치를 고려하는 위치 인코딩(Positional Encoding)은 어텐션 메커니즘과 함께 트랜스포머의 성능을 개선하였다.

13 Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Lukasz Kaiser, and Illia Polosukhin. 2017. Attention is all you need. In Advances in Neural Information Processing Systems, pages 6000–6010



<그림 5> Transformer 모델 구조¹⁴

2.3.2. koBERT의 활용

트랜스포머를 활용한 다중의도분류 모델을 구축하기 위해 사전 훈련(Pre-trained)된 koBERT(Korean Bidirectional Encoder Representations from Transformers)를 활용하였다. koBERT는 기존 BERT의 한국어 성능 한계를 극복하기 위해 개발되었다. 위키피디아나 뉴스 등에서 수집한 수백만 개의 한국어 문장으로 이루어진 대규모 말뭉치(Corpus)를 학습하였으며, 한국어의 불규칙한 언어 변화의 특성을 반영하기 위해 데이터 기반 토큰화(Tokenization) 기법을 적용하여 기존 대비 27%의 토큰(Token)만으로 2.6% 이상의 성능 향상을 이끌어 냈다.¹⁵ 본 연구는 SKT에서 개발한 koBERT 모델로 허깅페이스의 Transformer 라이브러리¹⁶를 활용하여 미세조정(fine-tuning)을 거친 후 다중분류모델을 최종적으로 설계하였다.

2.3.3. 활용 데이터 셋

먼저 모델 구축을 위해 기존 데이터에서 ‘식품’ 카테고리에 해당하는 434,313 개의 행을 추출했으며, 이 중 서비스 이용자의 발화문(Question)에 해당하는 217,156 개의 행을 학습에 활용하였다. 소비자(고객)를 이해하기 위해서 상담원의 응대가 아닌 고객의 발화를 기준으로 모델을 학습시키는 것이 효율적이다. 기존에는 ‘식품’ 카테고리의 대분류가 ‘제품’, ‘배송’, ‘행사’, ‘포장’, ‘결제’, ‘교환, 결제 및 환불’, ‘웹사이트’, ‘AS’, ‘멤버십’, 총 10 개로 나뉘어 있었다. 그러나 ‘교환, 결제 및 환불’, ‘웹사이트’, ‘멤버십’으로 분류된 데이터의 개수가 여타 대분류에 비해 현저히 부족하여 ‘기타’ 대분류로 통합했다. 이에 대분류는 ‘제품’, ‘배송’, ‘행사’, ‘기타’, ‘포장’, ‘결제’, 총 6 개이며, ‘제품’, ‘배송’ 대분류의 경우 각각 103,929 개, 92,034 개로 데이터의 개수가 훨씬 많았다. 또한 ‘결제’ 대분류가 데이터의 개수가 3961 개로 가장 적으며, 각 라벨마다 균등한 개수를 추출하고자 대분류별로 각각 3,900 개씩 무작위로 추출하여 총 23,400 개의 발화문을 모델

14 Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Lukasz Kaiser, and Illia Polosukhin. 2017. Attention is all you need. In Advances in Neural Information Processing Systems, pages 6000–6010

15 <https://sktelecom.github.io> (SK Telecom, 2019)

16 <https://huggingface.co/skt/kobert-base-v1>

구축에 활용했다. 이후 대분류를 정수 인코딩해 주었으며, 데이터를 7.5 대 2.5의 비율로 분할하여 모델의 학습과 평가에 사용하였다.

2.4. 챗봇과 콜센터

콜센터에서 활용 가능한 음성 인식 분야로는 지능형 가상 비서(Intelligent Virtual Assistance)가 있는데 대표적인 지능형 가상 비서로는 텍스트 기반 챗봇이 있다. 챗봇은 기계 학습의 한 응용 분야로, 기업이 24 시간 동안 고객 및 잠재적 마케팅 문의에 대한 지원을 제공할 수 있게 한다.¹⁷ 24 시간 서비스 제공 외에도 챗봇은 서비스 효율의 측면에서도 효과적이다. Juniper Research (2019)에 따르면, 2023년까지 은행 챗봇은 기업과 소비자에게 25억 시간을 절약할 것으로 예측된다.¹⁸ 마지막으로, 챗봇은 높은 수준의 상호 작용을 갖춘 실시간 대화를 제공하여 기존 이메일 마케팅보다 훨씬 더 효과적으로 고객들의 관심을 확보할 수 있다.

이러한 측면에서 챗봇은 사용자의 의도를 파악하여 적절한 기능을 수행하거나 응답을 생성할 수 있는 효과적인 수단이다. 본 연구에서는 콜센터 질의 및 응답 데이터를 기반으로 식품 콜센터 상담 챗봇을 만들어 즉각적인 응답을 통해 상담 시간을 절약하고 식품 콜센터의 운영 비용을 절감할 수 있도록 한다.

식품 콜센터 상담 챗봇은 자연어 처리 분야에서 자주 사용되고 있는 트랜스포머(Transformer) 모델을 기반으로 개발하였다.

2.4.1 seq2seq 와 트랜스포머

식품 콜센터 상담 챗봇을 구현하기 위해 사용한 모델 중 하나가 Sequence-to-Sequence (seq2seq)이다. seq2seq는 입력된 시퀀스로부터 다른 도메인의 시퀀스를 출력하는 딥러닝 모델이다. 이 모델은 인코더(Encoder)와 디코더(Decoder)의 구조로 이루어져 있으며 두 모듈이 서로 협력하여 입력 시퀀스를 원하는 출력 시퀀스로 변환한다.¹⁹ 인코더-디코더 구조를 콜센터 챗봇에 적용해 인코더에서 단어를 학습하고 문장 벡터로 매핑하기 위해 훈련되고 이어서 디코더가 따라와 챗봇으로 전송될 응답 문장을 생성한다. 이를 바탕으로 RNN 구조를 기반으로 한 seq2seq 모델을 사용해 seq2seq의 입력 시퀀스는 질문 형식의 콜센터 발화문, 출력 시퀀스는 대답 형식의 발화문으로 잡아 모델을 학습시키고자 하였다.

그러나, RNN 구조를 기반으로 한 seq2seq 모델을 통해 콜센터 발화문을 학습한 결과 낮은 성능을 보였다. 이는 문장의 길이가 증가함에 따라 학습 성능이

17 Amit Kumar Kushwaha, Arpan Kumar Kar. (2020) Language Model-Driven Chatbot for Business to Address Marketing and Selection of Products. International Working Conference on Transfer and Diffusion of

IT (TDIT), Tiruchirappalli, India. pp.16-28, 10.1007/978-3-030-64849-7_3.

18 Aishwarya Ramesh, Vaibhav Chawla. (2022) Chatbots in Marketing: A Literature Review Using Morphological and Co-Occurrence Analyses. Journal of Interactive Marketing 2022, Vol. 57(3) 472-496.

19 시퀀스-투-시퀀스(Sequence-to-sequence). (2023.09.26). <WikiDocs>. Available : <https://wikidocs.net/24996>

저하된다는 것을 이유로 들 수 있다. seq2seq 에서 인코더의 출력 시퀀스는 고정된 길이의 벡터인데 긴 문장이 입력될 경우 짧은 문장이 입력됐을 때와 똑같은 길이의 벡터로 밀어 넣어야 하기 때문에 필요한 정보를 다 담지 못하게 된다.²⁰ 이를 해결하기 위해 기존의 seq2seq 의 구조인 인코더-디코더를 따르면서 인코더와 디코더를 어텐션 메커니즘으로 개선한 트랜스포머 (Transformer) 모델을 사용하여 기존 RNN 을 활용한 seq2seq 의 한계를 극복하고자 하였다.

챗봇에서의 트랜스포머 모델은 다중 클래스 분류보다 더 복잡하다. 다중 클래스 분류는 인코더만을 필요한 것에 비해, 챗봇은 인코더-디코더를 모두 필요로 한다. 인코더는 입력 시퀀스를 받아 self-attention 을 적용하고, 그 결과를 디코더에 전달한다. 디코더는 출력 시퀀스를 생성할 때, 인코더의 출력과 self-attention 을 활용하여 각 시점에서 중요한 입력 부분에 집중한다. 또한, Transformer 는 단어의 상대적인 위치 정보를 학습하기 위해 포지셔널 인코딩(Positional Encoding)을 도입하였다.

이러한 구조는 특히 콜센터 발화문과 같은 긴 시퀀스를 처리하는 데 효과적이며, 학습 성능이 기존의 seq2seq 모델보다 우수함을 입증하였다. 위의 그림은 Transformer 의 구조를 시각적으로 보여준다. 결과적으로, 콜센터 챗봇에서는 문장의 길이에 상관없이 높은 성능을 보이며, 정보 손실 문제를 효과적으로 극복하였다.

2.4.2 활용 데이터셋

콜센터 챗봇은 앞서 말한 ‘식품’ 카테고리에 해당하는 데이터셋을 기반으로 개발을 진행하였다. 총 434,312 개의 발화문을 217,156 개의 질의 (발화문 Q)와 217,156 개의 응답(발화문 A)으로 분류해 챗봇 모델 개발에 필요한 데이터를 확보하였다.

20 Tian Shi, Yaser Keneshloo, Naren Ramakrishman, and Chandan K. Reddy. (2020) Neural Abstractive Text Summarization with Sequence-to-Sequence Models. ACM Trans. Data Sci. 1, 1, Article 1 (January 2020), 35 pages. <https://doi.org/10.1145/3419106>

발화문 (Q)	발화문 (A)	QA번호	인텐트 (대)	인텐트 (중)	인텐트 (소)
립밤 2만원 이상을 사면 무료 배송으로 아는데 여기가 죽도 추가로 몇 개 더 주문해도 추가 배송비 없	박스액 합표가 되지 않을 수도 있어 정확한 답변 드리지 못하는 점 양해 부탁드립니다	46175	배송	비용	질문
해마로 기준 6개 이상이고 북음밥 기준으로는 50개 이상인데 해마로 케이준 1통과 북음밥 10통 정도	일단 두 제품이 같이 담기면 최소 수량 부과인 6개 이상은 시스템 상 자동부과	40543	배송	비용	질문
마트 원데이는 무료 배송이라고 있었는데 왜 결제를 하려고 하니까 배송비 3000원이 붙는 건가요?	1KG 5 맥 이 상 무료배송 상품입니다.	15426	배송	비용	질문
제주도 추가 배송비 있나요?	문의해주셔서 감사해요.	226944	배송	비용	질문
물건이 오지도 않았는데 취소하게 되면 3천원이 빠지더라고요 요 반품 택배사들이 오는 것도 아닌데 이	운송장 발행되어 택배사에서 발송하면 반품 배송비가 발생해요	229560	배송	비용	질문
배송비 문의 구매비와 배송료 8000원만 거내면 되는 건가요?	이 전문의 글에 안내해드렸으니 확인해주시기 바랍니다. 궁금하신 사항은 언제	70853	배송	비용	질문
무료 배송 건에 종각 김치같이 배송받으려 하니 배송비가 추가되네요 어떻게 해야 하나요?	무료 배송 상품과 유료배송 상품을 같이 구매한다고 해서 유료배송 상품이 무료	33379	배송	비용	질문
제주도 추가 배송비 있나요?	네 추가 배송비는 없습니다.	261491	배송	비용	질문
제주도 추가 비용 얼마인지 알 수 있을까요?	무게가 있다보니 4000원이 나오네요. 도음 되시길 바랍니다.	198157	배송	비용	질문
배송비가 무료 네요 배송비가 무료인데, 두 개나 세 개 구매하면, 더 할인 안되나요?	복수 구매 시에도 할인은 적용되지 않습니다.	15690	배송	비용	질문
무료 배송인 제품이라 같이 구매하는 데도 배송비 또 내야 하나요?	무료 배송 상품은 현재 묶음배송이 되지 않는 단일 제품입니다. 무료 배송 제품	154541	배송	비용	질문
배송비 있나요?	블루베리 배송비는 3000원 부과됩니다.	55029	배송	비용	질문
제주도 추가 배송비있나요?	제주도 추가 배송비 없음을 안 내드려요.	266348	배송	비용	질문
배송비요아린이 흥상도 같이 주문했는데 무료 배송 안 되나요?	무료로 배송됩니다. 혹시 배송비 결제되면 알려주세요.	198174	배송	비용	질문
제주도 추가 배송비 있나요?	넵 제주의 경우 기본 배송료는 무료 배송되며 추가 운임은 3000원 발생이 되니	228904	배송	비용	질문
수입과자사도 무료 배송이 적용되지 않는데 오피조크렛 사면 무료 배송이 아닌가요?	상품에 기본 배송비는 2500원이 적용됩니다. 추가 구성품은 함께 사시면 별도	28331	배송	비용	질문
우영차랑 같이 주문할려니 배송비가 5천원이 드네요 묶음 배송 메뉴에도 우영차는 없고 판매자가 같	묶음 배송 설정에서 잘못되어 있는 것 같은데 묶음 배송 가능으로 처리해 놓았	126278	배송	비용	질문
갓김치와 들깨장장 같이 주문하려는 대갓김치는 무배고들깨장은 배송비가 붙어요. 둘이 같이 하면 둘	문의하신 갓김치 현재 행사 중으로 저렴한 가격으로 판매되고 있어서 갓김치도	36837	배송	비용	질문
제주도 추가 배송비 있나요?	제주도는 박스당 3천원의 도 선료가 발생되요.	267330	배송	비용	질문
라면이랑 컵밥 구매 시 컵밥 무료 택배인데 라면 같이 구매해서라면 수령 후 지불로 하면 배송비는 무	휴가 일정으로 배송 지연되어 7월 15시 이전 주문 시 8일 출고 예정이십니다.	5480	배송	비용	질문
한 번에 40개만 주문 가능하네요 10개 더 주문하러는 데 배송비 3천원 어떻게 해야 하나요?	아50명 주문을 희망하셨던 거군요. 그러시면 배송비 3천원 포함 10명 추가로 경	113449	배송	비용	질문
묶음배송요정요류원 흑설랑 15KG +백설랑3KG 2개 샀는데 묶음배송 가능하죠?	상품 상세 설명에도 보셨다시피 15KG 설랑은 파손이 많은 관계로 묶음 배송을	38069	배송	비용	질문
배송 무료 배송은 없는 거예요?	네 택배비 2500원 부담하셔야 합니다.	75440	배송	비용	질문
착불배송비 28000원이고 상세 페이지 책비 40000원 써 있던데 총 배송비만 68000원인 거요?	착불로 4만원만 내주시면 되십니다.	176147	배송	비용	질문
30개 정도시키려면 택배비가 어찌 되나요?	15팩 이상 주문하시면 택배비 5500원에 보내드립니다 30팩도 5500원입니다.	42813	배송	비용	질문
배송비가 5KG 에 6000원이나 하나요?	무게나 크기 등에 따라 배송비는 추가될 수 있는 점 구매에 참고 부탁드립니다.	13336	배송	비용	질문
몇 개 주문해도 택배비는 그냥 2500원인 거요?	최대 18개까지 1박 소포장 가능하며 박스 당 배송비 2500원 부과되요.	229088	배송	비용	질문
왜해당 제조사보다 배송비가 비싸나요?	해당 제조사행사로 인해 배송비가 낮춰졌습니다. 현재는 행사가 끝나서 원래 비	181049	배송	비용	질문
무료 배송 5만원 이상 무료 배송이라고 되어 있는데 배송비가 결제되네요 지난번 구매 때에도 무료 배	네 착 불로 하시면 무료 배송되십니다.	94107	배송	비용	질문
모듬어묵이랑 같이 주문하는데 이강 배송료를 왜 따로 받으시나요?	모듬어 묵 상품의 경우 할인이 커서 다른 상품과 묶음 배송으로 지정이 어려	41321	배송	비용	질문
버게트랑 밀긴 맥북이 묶음되나요?	저희 상품은 모든 상품 묶음 배송 가능합니다 많은 사랑 바랍니다.	22931	배송	비용	질문
마장동서 마포까지 책비 어느 정도 들까요?월요일에 주문하고 월요일 바로 픽도 가능할까요?	15000원에서 20000원 정도 나옵니다 월요일 당일로픽 가능합니다.	150852	배송	비용	질문
제주도 추가 배송비가 얼마인가요?	추가 배송비 3000원 4000원 정도 더 드신다고 합니다.	159449	배송	비용	질문

<그림 6> 챗봇 모델 학습에 사용된 데이터의 예시

다음과 같은 자연어 처리 과정으로 챗봇 모델을 구축하였다.

1. 텍스트 전처리와 단어 집합 생성
 - 단어 토큰화, 정규화, 어간 추출, 불용어 처리 등의 과정을 거친다.
2. 정수 인코딩
 - 토큰화된 단어에 정수를 부여하였다. 빈도수 순으로 단어집합을 구축한다.
3. 인코더와 디코더 입력
 - 발화문을 입력데이터로 사용한다.
4. 트랜스포머 모델 생성
5. 챗봇 평가
 - 생성된 응답과 기존의 응답을 비교한다.

제3장 최종 연구결과

3.1. 토픽모델링과 버토픽

3.1.1. LDA 와 버토픽의 성능 비교

LDA 와 버토픽의 성능 비교지표로, 일관성 점수(coherence score)를 활용하였다. 일관성 점수는 토픽 모델링의 평가 방법의 하나로, 토픽 내에 출현하는 단어 간의 유사성을 수치화한 것이다. 일관성 점수는 0 에서 1 까지의 스케일로, 낮은 유사성은 0 의 점수를 가지고, 높은 유사성은 1 의 점수를 가진다.

$$c(w_i, w_j) = \log \frac{D(w_i, w_j) + 1}{D(w_i) \cdot D(w_j)} \quad \text{식 (2)}$$

$D(W_i)$ 는 W_i 가 단독으로 출현하는 문서의 개수를 나타내며, $D(W_i, W_j)$ 는

W_i, W_j 가 동시에 출현하는 문서의 개수를 의미한다.

LDA 와 버토픽 모델링에 각각 같은 토픽의 개수를 할당하고, 일관성 점수를 측정하였다. 6 개의 상담 의도에서 모두 BERTopic 에서 더 높은 일관성 점수를 도출되었다. LDA 의 평균 일관성 점수는 0.3889 이며, 버토픽의 평균 일관성 점수는 0.5258 으로 나타났다. 토픽 모델링 분석을 위해서는 LDA 보다 버토픽이 좋은 성능을 가지고 있음을 일관성 점수로 확인하였다.

intent	LDA	BERTopic
제품	0.313178488	0.445447517
배송	0.398358939	0.501187678
행사	0.347334274	0.455602173
포장	0.4358610	0.525796703
결제	0.493910672	0.820606456
기타	0.344725824	0.406455185

<표 3> 일관성 점수(coherence socre)

3.1.2. LDA 와 버토픽의 결과 비교

앞서 살펴보았듯이, 요청사항 의도 중, ‘제품’과 ‘배송’이 대부분을 차지하고 있다 (90% 이상). 따라서, 가장 빈번하게 콜센터로 문의가 들어오는 ‘제품’ 의도와 ‘배송’ 의도의 다양한 주제를 이 보고서에서는 집중적으로 살펴보도록 한다.

3.1.2.1. ‘제품’ 의도 발화문의 토픽모델링 결과분석

토픽모델링 결과를 해석하기에 앞서, ‘제품’ 의도 발화문에서 주로 등장하는 단어들을 살펴보자.



<그림 7> ‘제품’ 의도 발화문의 주요 단어 구성

<그림 7>는 ‘제품’ 의도 발화문의 워드 클라우드 (word cloud) 결과값이다. 워드 클라우드란 단어의 빈도에 따라 크기를 다르게 하는 시각화 기법 중 하나이다. ‘제품, 상품, 보관, 유통, 기한’의 순으로 상위 빈출됨을 확인할 수 있다. 주로 제품의 품질 및 정보 관련 단어가 상위 빈출되며, ‘고구마, 유산균, 비타민’ 같은 구체적인 단어도 확인된다.

초매개변수(하이퍼파라미터)를 다르게 설정한 결과 ‘제품’ 의도 발화문의 토픽 개수는 22 개가 적합함을 확인하였다. <표 4>는 LDA 의 총 22 개의 토픽 중 유의미하다고 판단되어 토픽 주제어를 제시한 10 개의 결괏값이며, <표 5>는 BERTopic 에서의 22 개의 토픽 중 유의미하다고 판단되어 주제어를 제시한 18 개의 결괏값이다. 각 토픽에 따른 주요 구성 단어는 중요도 순으로 정렬되어 있다.

주제어	Topic	주요 구성 단어
성분	2	퍼센트, 성분, 섭취, 함유, 함량, 비타민, 콜라겐
보관 방법	4	사용, 보관, 냉동, 고구마, 상태, 냉장
행사 여부	7	판매, 현재, 행사, 할인, 종료, 업체
단백질보충제	8	선택, 단백질, 표시, 영양, 성분, 나트륨, 대두, 웨이크
가격 변화	10	가격, 금액, 차이, 때문, 재료
캡슐커피	11	호환, 캡슐, 네스프레소, 커피, 포장, 박스, 돌체
김치	14	부분, 발송, 김치, 처리, 사이즈, 배추, 국산, 비율
건강식	17	복용, 원래, 문제, 안심, 가슴, 현미, 양배추, 자연
할인 적용	18	확인, 옵션, 쿠폰, 다시, 적용, 수정, 상세
커피	21	추가, 카페인, 종류, 갑자기, 기본, 시럽, 펌프, 카페

〈표 4〉 ‘제품’ 의도 발화문의 LDA 모델링 결과

LDA 와 버토픽 결과를 비교해 볼 때, 버토픽의 결과에서 유의한 주제가 빈번히 출현하는 것을 확인하였다. <표 4>의 여덟 번째 주제와 <표 5>의 열다섯 번째 주제는 단백질 보충제에 관한 것으로 동일하다. 하지만, 주요 구성 단어는 다르다. <표 4>와 <표 5>를 구체적으로 비교하여 보면, 버토픽의 결괏값이 토픽 주제어를 설정하기에 유용한 구성 단어들의 출현함을 확인할 수 있다. LDA 의 여덟 번째 주제의 구성 단어는 ‘선택, 단백질, 표시, 영양, 성분, 나트륨, 대두, 셰이크’로 단백질 보충제의 성분에 관한 단어로 구성되어 있다(<표 4> 참조). 반면에 버토픽의 열다섯 번째 주제는 ‘근육’, ‘제품’, ‘체중’, ‘웨이’, ‘운동’, ‘증가’, ‘도움’으로 단백질 보충제의 성능 및 기대효과에 대한 단어로 구성되어 있다(<표 5> 참고). 이를 통해 LDA 보다 버토픽이 더 구체적인 관련 주제어를 제시하고 있다.

주제어	Topic	주요 구성 단어
상품 입고일	0	['토요일', '월요일', '문건', '건강', '방금']
임산부 섭취	1	['임산부', '개월', '아이스팩', '선택', '확인']
제조일자	2	['최근', '일자', '판매', '주문']
보관 방법	4	['권장', '냉장고', '해동', '수량', '저녁', '아침']
섭취량	5	['인분', '상품', '콜라겐', '칼로리', '퍼센트']
초콜렛	7	['초콜렛', '우유', '사용', '파베초콜릿', '몰드', '초코']
원산지	8	['국내', '기한', '유통', '식물성', '망고', '애플', '햅쌀']
유기농	9	['유기농', '제품', '상품', '사용', '현재']
GMO	10	['제품', '인증', '농약', '사용', '상품', '재배', '친환경', '비료', '화학']
식품 안전성	13	['식약처', '검사', '생산', '판매', '상품', '제조']
품질	14	['현재', '품질', '판매', '제품', '상품', '중단',]
단백질보충제	15	['근육', '제품', '체중', '웨이', '운동', '증가', '도움']
수산물	16	['새우', '오징어', '생선', '각테일', '부위', '어류']
맷음말	17	['오늘', '정보', '상세', '내용', '주말']
수입 곡류	18	['캐나다', '상품', '귀리', '판매', '제품', '제조']
수입산	19	['베트남', '제품', '원산지', '산입', '수입']
육류	20	['고기', '부위', '스테이크', '찌개', '두께']
키위	21	['칠레', '키위', '판매', '품질', '상품', '막바지']

<표 5> ‘제품’ 의도 발화문의 버토픽 모델링 결과

또한 버토픽은 LDA 에 비해서 더욱 구체적인 주제어를 제시하고 있다. LDA 는 제품의 정보와 관련한 토픽이 성분 (Topic 2), 보관 방법 (Topic 4)뿐이다 (<표 4> 참조). 특히 LDA 는 <표 3>에서 확인하였던, 상위 빈출 단어에 기반하여 한정적인 토픽이 출현된다. 이에 비해 버토픽은 제조일자 (Topic 2), 섭취량 (Topic 5), 원산지 (Topic 8), 유기농 (Topic 9), GMO (Topic 10), 식품 안정성 (Topic 13)으로

배송지 변경	13	변경, 문의, 방문, 주소, 직접, 다시, 배송지
도서산간	14	도착, 지역, 제주도, 우체국, 통운, 출발
명절	15	추석, 정상, 선물, 말씀, 미리, 날씨, 흥게
배송조회	16	송장, 번호, 조회, 상태, 세트, 메모, 운송

<표 6> ‘배송’ 의도 발화문의 LDA 모델링 결과

‘배송’ 의도 발화문의 토픽모델링에는 20 개의 토픽을 할당하였다. <표 6>은 LDA 의 20 개의 토픽 중 유의한 주제어를 찾아낸 13 개의 토픽이며, <표 7>은 버토픽의 20 개의 토픽 중 유의한 주제어를 찾아낸 17 개의 토픽이다. ‘배송’ 의도 발화문에서도 역시 버토픽 모델링에서 유의한 주제와 구체적인 구성 단어가 등장하였다.

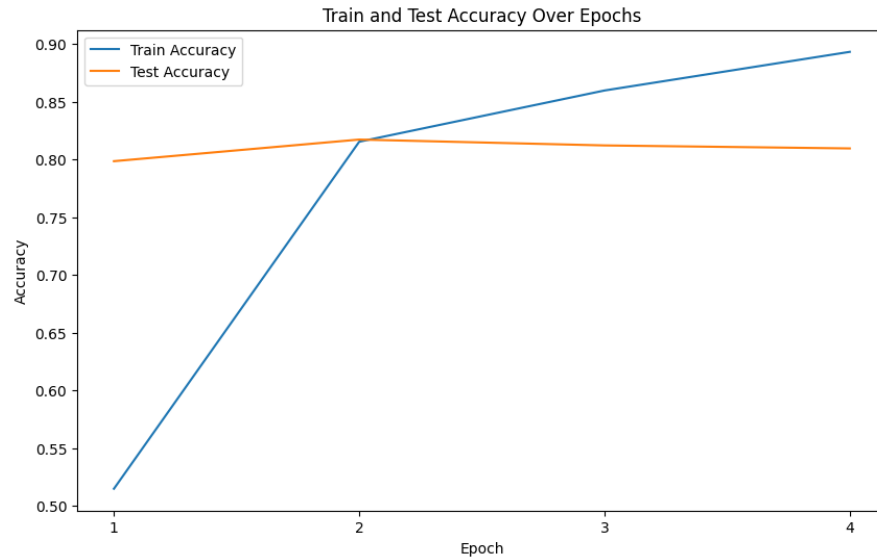
배송 특성상 LDA, 버토픽에서는 비슷하게 요일과 시간에 관련한 토픽이 출현된다. 다만, 버토픽의 경우 연휴 지연 안내(Topic 3), 당일 발송 (Topic 8), 연휴 출고일 (Topic 10)과 같이 상세한 토픽을 확인할 수 있다. 또한 합배송 (Topic 12), 해외 배송 여부 (Topic 18), 해외 배송비 (Topic 19) 같이 배송에서의 다양한 사례가 토픽으로 확인되며, 김치 배송 (Topic 0), 농작물 (Topic 14), 구황작물 (Topic 17) 같이 배송 품목 역시 토픽으로 확인할 수 있다 (<표 7> 참고).

주제어	Topic	주요 구성 단어
김치 배송	0	['일요일', '김치', '일이', '상태', '일주일', '입금']
수령 일자	2	['배송', '내일', '오늘', '도착', '택배', '대체', '발송']
연휴 지연 안내	3	['정상', '연휴', '주말', '작업', '물류', '명절', '공휴일', '수령']
날씨 배송 상태	5	['아이스팩', '아이스박스', '김치', '수령', '택배', '박스']
소요 시간	6	['소요', '당일', '오늘', '결제', '이전', '택배']
택배 업체	7	['회사', '배송', '이용', '인지', '업체', '가가']
당일 발송	8	['당일', '이후', '발송', '상품', '마감', '이전', '문건', '평일', '익일']
출고 안내	9	['발송', '주문', '출고', '배송', '상품', '생수', '완료', '오늘']
연휴 배송	10	['주문', '출고', '한글날', '순차', '빈통', '배송', '현재', '확인', '휴무']
수령 일자	11	['금요일', '주문', '오늘', '토요일', '발송', '배송', '도착', '목요일', '출고']
합배송	12	['판매', '상품', '배송비', '묶음', '제품', '때문', '무게', '지역']
천재지변	13	['직원', '마이', '코로나', '최대', '태풍', '중이', '지연', '양해']
농작물	14	['수확', '수확량', '출고', '농산물', '현재', '지연', '상품']
구황작물	17	['고구마', '감자', '현재', '숙성', '수확']
해외배송 여부	18	['해외', '배송', '미국', '베트남', '제품', '일본', '거주']
해외 배송비	19	['독일', '상품', '현지', '출고', '지연', '세관', '발송', '통관']
우체국 택배	20	['우체국', '택배', '이용', '사용', '대봉', '배송']

<표 7> ‘배송’ 의도 발화문의 버토픽 모델링 결과


3.2. 트랜스포머를 활용한 다중의도분류 모델

3.2.1. 트랜스포머 모델 학습과 훈련결과



<그림 9> 학습결과와 예측모델의 정확도(Accuracy)

학습 과정에서 에포크(Epoch)를 100 회로 설정하였다. 과적합을 방지하기 위해 설정한 조기 종료 기능으로 인하여 학습이 초기에 중단되었으나 학습은 충분히 이루어졌다. 초기에는 에포크의 훈련 정확도(Train Accuracy)가 51.4%에 그쳤지만, 빠른 기간 내로 81.5%를 기록하며 정확도를 급격하게 상승했고, 테스트 정확도는 2 회의 에포크 이후 81.7%를 기록했다(<그림 9>). 훈련 손실(Train Loss)은 모델이 얼마나 정확하게 예측을 수행했는지를 나타내는 지표이며, 학습이 진행됨에 따라 최소화되어야 한다. 모델의 학습 과정에서 최초의 에포크에서는 4 에 가깝던 훈련 손실이 급격하게 감소하며 안정적으로 1 에 가까운 값을 출력했다(<그림 10>). 이는 모델이 훈련 데이터에 점차 더 효과적으로 학습되고 예측 성능이 향상되었음을 의미한다.



<그림 11> 학습결과와 훈련손실(Train Loss)

3.2.2. 소비자 의도 예측모델

트랜스포머 다중 클래스 모델은 주어진 소비자의 발화문에 따라 소비자의 의도를 분류한다. 다음은 콜센터에 접수된 사용자의 문의사항에 따른 다중 클래스 예측모델의 예측 결과이다. 현재 약 82% 정확도로 의도를 예측한다.

안녕하세요. 오투기 주문센터입니다. 음성 ARS 서비스에 연결되었습니다.
빠른 서비스를 제공하기 위해 문의 내용을 말씀해주시면 곧바로 해당 부서로 연결해드리겠습니다.
문의 내용을 자유롭게 말씀해주세요.

사용자 문의 : 울릉도도 배송이 되나요
>> 해당 발화문은 '배송' 대분류에 해당합니다.
배송 관련 부서로 전화 연결 도와드리겠습니다. 상담원을 연결합니다.

<그림 11> 다중 클래스 분류 서비스 입출력 결과 예시

<그림 11>은 구현된 서비스의 예시이다. 서비스 이용자(소비자)는 기계 음성의 안내에 따라 ‘울릉도도 배송이 되나요’와 같은 필요한 요청사항을 질의하면 음성이 텍스트로 변환되고, 해당 텍스트가 koBERT 기반 다중분류모델의 입력으로 사용되어 ‘배송’이라는 대분류로 예측하여 그 결과로 출력한다. 이후 ‘배송’ 대분류에 해당하는 기계 음성이 재생되며 관련 부서 상담원과 자동 연결하는 서비스 모델이다(즉, ‘울릉도도 배송이 되나요’라는 발화문이 데이터로 입력되어 ‘배송’이라는 의도가 예측되고 관련 부서의 상담원으로 자동으로 전환되는 모델이다).

이 서비스 모델은 다음과 같이 구축된다. 학습과 평가가 완료된 다중 클래스 분류모델에 음성 재생, 음성 녹음 기능을 연결하여 전화자동응답시스템(ARS) 서비스를 구축하였다. 음성 재생 함수는 파이썬(Python) 환경에서 비디오 게임

개발을 위해 GUI를 구현해 주는 모듈인 pygame의 사운드 라이브러리를 사용하였다. 음성 녹음 함수의 경우 안내문 종료 이후 기본적으로 5초의 응답 시간을 제공하며, 5초 이후에는 서비스 이용자의 음성이 3초 이상 연속적으로 인식되지 않을 경우 함수 작동이 중지된다. 따라서 기존에는 기계 음성 안내에 의해 상담원과 연결되기까지의 시간이 고정되어 있었으나, 본 서비스는 이용자의 의사에 따라 상담원까지 연결되는 시간이 가변적이며 민원 사항에 따라 서비스 이용 시간을 크게 단축할 수 있다. 이후 녹음된 음성을 구글(Google)의 API를 활용하여 한글 텍스트로 STT(Speech to Text) 변환하며, 해당 텍스트를 다중분류모델의 입력으로 사용한다. 이후 출력된 결과에 따른 음성 안내 파일을 재생하여 이용자를 민원 내용에 적합한 특정 부서의 상담원에게 빠르게 연결한다.

3.3. 챗봇과 콜센터

Input: 배송 언제 되나요?
Output: 네 오늘 발송 가능합니다 .

<그림 12> 챗봇 입출력 결과 예시(1)

본 연구에서는 트랜스포머(Transformer) 모델을 활용하여 구축한 시스템 콜센터 상담 챗봇의 결과가 효과적으로 나타나는 것을 확인하였다. 트랜스포머의 강력한 언어 이해 및 생성 능력 덕분에 챗봇은 사용자의 쿼리에 맞는 답변을 제공하였다. 예를 들어, <그림 12>와 같이 챗봇은 ‘배송 언제 되나요?’라는 사용자의 질문에 ‘네, 오늘 발송 가능합니다.’와 같이 정확하고 사용자 친화적인 응답을 생성하였다. 그러나, 챗봇의 응답 중 일부는 어색하게 들리는 경우가 발생하였다. 그에 대한 이유는 다음과 같다.

Input: 제품 추가 구매에 대한 추가 배송비가 있나요?
Output: 네 맞습니다 .

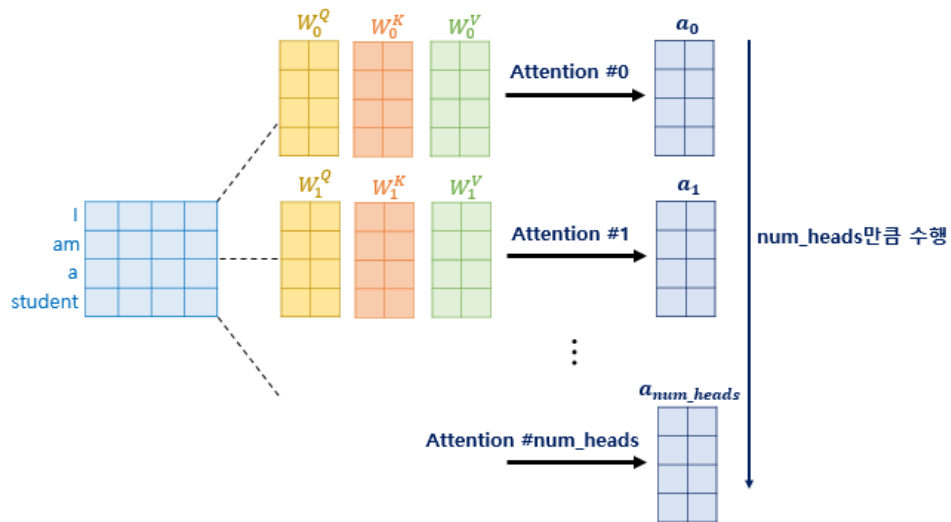
<그림 13> 챗봇 입출력 결과 예시(2)

<그림 13>의 경우, 챗봇은 사용자의 질문에 명확하게 응답하지 못하고 있다. 서비스 이용자는 ‘제품 추가 구매에 대한 추가 배송비가 있나요?’라는 구체적인 질문을 시작하였다. 그에 반해, 챗봇은 단순한 ‘네 맞습니다.’라는 답변을 제시하였고, 추가 배송비의 금액이나 조건에 대한 구체적인 정보를 제공하지 않았다. 사용자가 원하는 정보를 충족시키지 못한 것이 의사소통의 한계로 이어졌다.

이러한 한계를 극복하기 위해서는 먼저, 챗봇이 더 구체적이고 유용한 정보를 제공할 수 있도록 모델의 훈련 데이터를 다양화하고 향상시키는 것이 필요하다. 또한, 추가적인 훈련과 파라미터 조정이 필요하며, 모델의 성능을 신속하게 평가하고 개선하기 위한 지속적인 평가 프로세스가 구축되어야 한다. 더 나아가,

사용자의 의도를 더 명확하게 파악하고 상세한 정보를 제공할 수 있는 향상된 언어 모델의 도입도 고려할 수 있을 것이다.

이러한 한계에도 불구하고 챗봇의 결과가 양호한 것은 트랜스포머의 임베딩 차원과 멀티 헤드 어텐션 등의 기술적 특성에 기인한다.



<그림 14> 멀티 헤드 어텐션의 구조²¹

첫째로, 트랜스포머는 고차원의 임베딩을 사용하여 언어의 다양한 특징을 반영할 수 있다. 이는 단어와 문맥의 복잡한 관계를 높은 수준으로 이해하고 반영할 수 있도록 하는 데 크게 기여하였다. 둘째로, 멀티 헤드 어텐션 메커니즘은 여러 어텐션 헤드를 동시에 사용하여 다양한 문맥을 파악하는 데 기여하였다.²² 각 헤드는 입력 문장의 다른 부분에 집중함으로써 모델이 여러 측면에서 문맥을 이해하고 정보를 추출할 수 있도록 했다. 이는 사용자의 질문에 민감하게 반응하여 정확하고 풍부한 응답을 생성하는 데 도움을 주었다. 마지막으로, 트랜스포머의 셀프 어텐션 메커니즘은 문장 내에서의 단어 간 상호작용을 강화함으로써 문맥을 보다 잘 이해하고 처리할 수 있게 하였다. 이는 챗봇이 단일한 헤드 어텐션보다 더 복잡한 언어 구조를 이해할 수 있도록 하였다. 따라서, 트랜스포머의 기술적 특성은 챗봇이 사용자의 의도를 더 정확하게 파악하고 응답을 생성하는 데 기여하여 사용자 경험을 향상시켰다.

²¹ 트랜스포머 (Transformer). (2023.09.13). <WikiDocs>. Available : <https://wikidocs.net/31379>

²² Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Lukasz Kaiser, and Illia Polosukhin. 2017. Attention is all you need. In Advances in Neural Information Processing Systems, pages 6000–6010

제4장 연구결과 고찰 및 결론

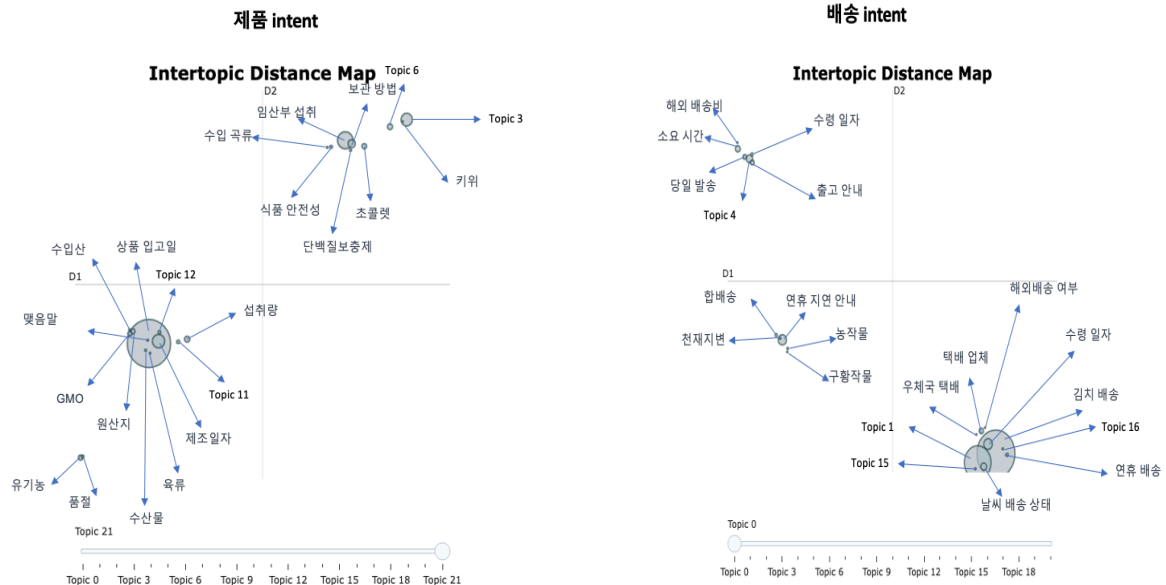
4.1. 토픽모델링과 버토픽

LDA와 버토픽(BERTopic) 두 방법론 중, 버토픽이 더욱 유의한 토픽을 도출함을 분석결과를 통하여 확인했다. 트랜스포머를 기반으로 문맥을 고려하는 버토픽은, 상위 빈출 단어에 기반하여 토픽을 도출하는 LDA보다 유의미한 토픽 출현 가능성이 높다는 것을 확인하였다. 또한 버토픽은 사전 학습된 트랜스포머를 미세조정(파인튜닝) 하기 때문에 더 좋은 성능을 보인다.

BERTopic으로 찾아낸 주제어를 정리하면 <표 8>과 같다.

제품		배송	
0	상품 입고일	0	김치 배송
1	임산부 섭취	2	수령 일자
2	제조일자	3	연휴 지연 안내
4	보관 방법	5	날씨 배송 상태
5	섭취량	6	소요 시간
7	초콜렛	7	택배 업체
8	원산지	8	당일 발송
9	유기농	9	출고 안내
10	GMO	10	연휴 배송
13	식품 안전성	11	수령 일자
14	품질	12	합배송
15	단백질보충제	13	천재지변
16	수산물	14	농작물
17	맷음말	17	구항작물
18	수입 곡류	18	해외배송 여부
19	수입산	19	해외 배송비
20	육류	20	우체국 택배
21	키위		

<표 8> BERTopic으로 찾아낸 ‘제품’ 의도 및 ‘배송’ 의도 발화문의 주제어



<그림 15> BERTopic intertopic Distance Map

<그림 15>의 Intertopic Distance Map 이란 토픽 간의 유사도를 시각화한 것이다. ‘배송’ 의도 발화문의 경우, 네 번째 토픽 (Topic 4) 에는 ‘해외배송비’, ‘소요시간’, ‘당일발송’, ‘수령일자’, ‘출고안내’ 등의 주요 구성 단어가 하위로 분류되는 것을 시각적으로 확인할 수 있다. 또한 이 토픽에서 서로 유사한 토픽과 비교적 유사하지 않은 토픽 또한 상대적 거리를 시각적으로 확인하여 판단할 수 있다.

버토픽을 통해 콜센터의 주요 문의 내용을 다시 한번 정리하면 다음과 같다.

1) ‘제품’ 관련 문의사항

‘제품’ 의도 발화문에서는 상품에 대한 정보와 주로 언급되는 제품 품목을 확인할 수 있다. 제품 정보에 있어서는 상품 입고일 (Topic 0), 제조일자 (Topic 2), 보관 방법 (Topic 4), 품질 (Topic 14)과 같은 기초 상품정보에 관한 문의를 확인할 수 있다. 또한, 임산부 섭취 (Topic 1)나 섭취량 (Topic 5), 식품 안정성 (Topic 13)을 통해 섭취 시 유의사항에 대한 문의가 이루어짐을 알 수 있다. 원산지(Topic 8) 및 수입 정보(수입 곡류 (Topic 18), 수입산 (Topic 19))에 대한 문의 역시 확인되었는데, 이러한 문의는 유기농(Topic 9) 및 GMO(Topic 10) 식품 여부까지도 이어진다. 주로 언급되는 상품으로는 초콜릿 (Topic 7), 단백질보충제 (Topic 15), 수산물 (Topic 16) 및 육류 (Topic 20)으로 확인했다. 이를 통해 고객은 주로 섭취하는 식품에 대한 안정성과 원산지, 기초 정보에 대해 문의하는 것을 알 수 있다.

2) ‘배송’ 관련 문의사항

배송에 있어서는 날짜 및 시간에 관한 토픽이 주로 확인된다. 이는 배송 일정에 관한 문의가 많기 때문이다. 이와 관련된 토픽은 수령 일자 (Topic 2), 소요 시간 (Topic 6), 당일 발송 (Topic 8), 출고 안내 (Topic 9) 등이다. 또한 택배 관련 정보에 관한 문의가 많음을 확인할 수 있다. 이러한 택배 관련 문의는 업체 (택배 업체 (Topic 7), 우체국 택배 (Topic 20))와 합배송 (Topic 12) 관련 문의 그리고 해외 배송(해외배송 여부 (Topic 18), 해외배송비 (Topic 19))으로 구분된다. 연휴(연휴 지연 안내 (Topic 4), 연휴 배송 (Topic 10))나 천재지변 (Topic 13) 같은 상황에 따른 배송지연 문의 역시 토픽으로 확인되었다. 배송과 관련하여 농산물(농작물 (Topic 14), 구황작물 (Topic 17)) 제품 관련 토픽이 주로 확인되었다.

이를 통해 고객은 주로 언제 제품을 수령할 수 있는지에 대해서 주로 문의함을 확인할 수 있다. 또한 합배송과, 해외 배송과 같이 특이 배송 상황에 대해서 문의함을 확인할 수 있다.

4.2. 트랜스포머를 활용한 다중 클래스 의도분류 모델

전화자동응답시스템에 koBERT 를 기반으로 구축된 다중분류모델을 연결하면 서비스의 구성 단계가 음성 안내-고객 응답-상담원 연결로 단축된다. 서비스 이용자는 별도의 불필요한 음성 안내에 대응할 필요 없이 본인의 민원 사안만 말하면 자동으로 해당 부서로 전화 연결된다. 이는 기존의 버튼식 전화자동응답시스템의 과정이 크게 단축된 것으로 이용자의 편익을 크게 증가시킬 수 있다. 또한 기존의 경우 기계 음성이 중심이 되어 서비스가 운용되었지만, 본 연구에서 개발한 모델의 경우 이용자가 주체가 되어 서비스를 이용할 수 있다는 점 역시 차별점이다.

과학기술정보통신부(장관 이종호)는 2023년 2월 2일, 총 211개 기관(민간기업 182개, 공공기관 29개)을 대상으로 실시한 평가 결과를 바탕으로 「2022년도 전화자동응답시스템(ARS) 운용실태 분석·평가」를 발표하였다. 조사결과 우수기관의 경우 평균 상담원 연결시간이 18.3초에 불과했으나, ‘미흡’ 26개 기관 중 15개 기관은 상담원 대기시간이 95초 이상 소요되는 것으로 파악되었다. 한편, 2024년부터는 기존의 버튼식 전화자동응답시스템 이외에도 인공지능(AI)을 활용한 챗봇, 보이는 전화자동응답시스템, 보이스 봇 등 서비스 유형의 다양화에 따라 신유형의 운영 평가지표에 따른 결과가 발표될 예정이다.²³ 본 연구에서 개발한 서비스를 실용화한다면 신유형의 운영 평가 지표에 부합하는 최상위점을 획득할 수 있다. 또한 발화 이외의 기계 음성의 안내 시간은 20초에 불과하고, 절차가 매우 간단하기 때문에 이용 난도가 굉장히 낮다. 보이는 전화자동응답시스템의 경우 스마트폰이 부재할 경우 아무리 간편하다 하더라도 사용이 불가능하다. 그러나 본 연구에서 개발한 서비스는 스마트폰 보급률이 떨어지는 노인 세대도 편리하게 상담원과 민원 내용을 상담할 수 있다.

²³ 「통신지원정책과, 2022년도 전화자동응답시스템(ARS) 운용실태 분석 및 평가결과 발표」 (과학기술정보통신부, 2023)

4.3. 챗봇과 콜센터

이 연구는 챗봇이 사용자의 배송 관련 질문에 어떻게 응답하는지에 대한 탐구를 수행하였다. 챗봇의 결과는 정확성과 빠른 응답 시간 측면에서 양호한 성과를 보였다. 특히, 챗봇이 ‘배송 언제 되나요?’와 같은 사용자 질문에 대해 신속하게 ‘네, 오늘 발송 가능합니다.’와 같이 정확한 응답을 생성함으로써, 사용자들에게 필요한 정보를 효과적으로 전달하는 데 성공하였다.

연구에서 강조된 주요 점 중 하나는 챗봇의 사용자 친화성이다. 챗봇은 간결하고 친근한 언어를 사용하여 사용자들이 쉽게 이해할 수 있도록 노력했다. 이는 사용자 경험을 향상시키고, 사용자들이 챗봇과 자연스럽게 상호작용할 수 있게 도왔다.

기술적으로, 연구에서는 자연어 처리와 기계 학습 기술을 사용하여 챗봇이 입력된 질문을 이해하고 정확한 응답을 생성하는 데 어떻게 활용되는지에 중점을 두었다. 이러한 기술적 세부 사항은 챗봇이 어떻게 작동하는지에 대한 투명성을 제공하고, 모델의 신뢰성을 높였다.

향후 연구 방향으로서는 더 나은 성능과 사용자 경험을 제공하기 위해 새로운 모델의 도입과 함께, 더 다양하고 복잡한 상황에 대응하는 방안을 모색할 것이다. 사용자 피드백 수집과 분석을 통해 모델의 강점과 개선점을 파악하고, 이를 토대로 지속적인 향상을 위한 노력을 기울일 것이다.

이 연구는 챗봇 기술이 실제 사용자 요구를 어떻게 충족시키는지에 대한 통찰을 제공하며, 챗봇을 개선하고 발전시키기 위한 기초를 마련하였다. 앞으로의 연구와 개발에 있어서 이러한 결과들이 챗봇 기술의 지속적인 진화를 이끌어낼 것으로 기대된다.

제5장 연구성과

5.1. 버토픽과 고객 문의사항 분석

콜센터 데이터를 활용하여 LDA와 버토픽의 성능을 비교하였다. 이론적인 측면뿐만 아니라 실제 결과를 통해 버토픽이 LDA보다 우수한 성능을 보여줌을 확인하였다. LDA와 버토픽(BERTopic) 두 방법론 중, 버토픽이 더욱 유의한 토픽을 도출함을 분석결과를 통하여 확인했다.

또한, 토픽 모델링을 통해서 방대한 양의 콜센터 민원의 주요 사항을 확인함에 있다. 특히 콜센터의 고객문의는 고객 만족도와 직결되기에 관리가 중요하다. 콜센터 문의사항의 주요 토픽을 토대로 고객의 관심사를 확인하고 이를 통해 콜센터 서비스 품질 향상에 활용할 수 있다. 구체적인 예로 제시된 토픽을 토대로 자동 응답 시스템을 개발하거나, 교육 프로그램을 강화하여 콜센터의 효율성을 향상할 수 있다. FAQ 자료를 구축하여 고객이 원하는 정보에 쉽게 접근할 수 있도록 하여 고객만족도를 향상시킬 수 있다.

5.2. 다중 클래스 의도분류 서비스 모델 개발

콜센터의 두 가지 주요 목표는 고객 만족도 향상과 운영 비용 절감이다. 콜센터는 합리적인 비용으로 효율적인 서비스를 제공하는 것을 목표로 운영된다. 운영 비용을 절감하기 위해 주로 사용되는 방법은 대화형 음성 응답(IVR)의 사용, 자동 통화 분배, 임금이 낮은 다른 국가로의 아웃소싱과 같은 프로세스 자동화이다. 다양한 방식으로 운영 비용을 줄였지만, 고객 만족도가 저해되고, 직원 이탈률이 높아졌으며, 고객 이탈률의 큰 개선을 달성하지는 못하였다. 특히, 대화형 음성 응답(IVR)은 사용자 인터페이스의 부실한 설계로 문제를 일으키고 있다. 최근 음성 인식이 가능한 IVR 시스템이 상당한 발전을 이루었다.

본 연구에서는 텍스트로 저장된 고객의 요청사항 혹은 소비자의 의도를 예측하는 모델을 구축하였다. 정확도 높은 예측은 사용자 인터페이스의 개선을 가져오며, 소비자의 만족을 증대시킨다. 따라서, 이 연구는 자동화된 콜센터 연구에 도움이 될 것이다. 하지만, 본 연구는 음성 녹음을 텍스트로 바꾸는 과정이 추가로 필요하다는 것에서 한계점이 있다. 본 연구의 후속연구로 진행해 볼 가치가 있다.

5.3. 챗봇 서비스 모델

콜센터의 두 가지 주요 목표를 달성하기 위해 필요한 또 다른 분야는 챗봇 또는 가상 에이전트 및 음성 인식 가능한 IVR(Interactive Voice Response)이다. 최근 몇 년 사이에 챗봇에 대한 연구가 급증하였으며, 실제 성능 또한 빠르게 개선되고 있다. 현재 챗봇은 일상 생활에서 많은 발전이 있었지만, 여전히 개별 분야(콜센터 도메인)에서의 연구는 더욱 진행되어야 하는 상황이다. 챗봇과 함께 대화형 IVR(Interactive Voice Response)과 같은 대규모 음성 대화 시스템도 발전하고 있다.

현대 챗봇 시스템에서 직면한 어려움 중 하나는 고객 의도 검출을 위한 정확한 자동 모델을 설계하고 의도를 예측하는 것이다. 앞서 다중 클래스 의도 예측 모델이 이 모델에 해당하는 것이었다면, 다음 단계는 의도에 맞춰 적절한 반응의 대화를 생성하는 것이다. 현재 본 연구는 적절한 반응의 대화를 생성한다는 점, 결과적으로 소비자의 불만족을 해소하는 방향으로 응답이 진행된다는 점에서 의의가 있다. 다만, 예측된 의도 분류 결과의 정확도를 높이고, 그에 맞는 대화형 지능을 개선하는 것이 더욱 필요하다. 이러한 한계점을 극복하기 위해, 앞으로 지속적인 연구가 필요하다.

제 6 장 참고문헌

1. 토픽 모델링. (2019.03.03). <WikiDocs>. Available: <https://wikidocs.net/30707>
2. Gallagher, R. J., Reing, K., Kale, D., and Ver Steeg, G. (2017). Anchored correlation explanation: topic modeling with minimal domain knowledge. Trans. Assoc. Comput. Linguist.
3. Blei, D.M.(2012), ‘Probabilistic topic models,’ Communications of the ACM, 55(4), 77-84.
4. Abuzayed, A. and Al-Khalifa, H. (2021). ‘BERT for Arabic topic modeling: An experimental study on BERTopic technique.’ Procedia Computer Science, Elsevier, Vol. 189, pp. 191-194, <https://doi.org/10.1016/j.procs.2021.05.096>.
5. 포티투마루, 콜센터(민원) 업무의 효율화를 위해 AI 기술을 활용한 ICC(Intelligent Contact Center) 관련 기술 개발에 활용할 수 있는 상담 내역 질의응답 학습데이터셋 구축 (AI-Hub, 2023)
6. Devlin, Jacob, et al. ‘Bert: Pre-training of deep bidirectional transformers for language understanding.’ NAACL 2019 (arxiv 2018.10)
7. OpenAI, GPT-3.5 Chatbot
8. Bag of words. (2019.03.03). <WikiDocs>. Available : <https://wikidocs.net/22650>.
9. 버트(Bidirectional Encoder Representations from Transformers, BERT). (2023.02.04). <WikiDocs>. Available : <https://wikidocs.net/115055>
10. Maarten Grootendorst. (2022.03.11). BERTopic: Neural topic modeling with a class-based TF-IDF procedure
11. Kukushkin, K., Ryabov, Y., & Borovkov, A. (2022) Digital twins: A systematic literature review based on data analysis and topic modeling. Data, 7(12), 173.
12. 버토픽(BERTopic). (2022.11.14). <WikiDocs>. Available: <https://wikidocs.net/162076>
13. Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Lukasz Kaiser, and Illia Polosukhin. 2017. Attention is all you need. In Advances in Neural Information Processing Systems, pages 6000-6010
14. Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Lukasz Kaiser, and Illia Polosukhin. 2017. Attention is all you need. In Advances in Neural Information Processing Systems, pages 6000-6010
15. <https://sktelecom.github.io> (SK Telecom, 2019)
16. <https://huggingface.co/skt/kobert-base-v1>
17. Amit Kumar Kushwaha, Arpan Kumar Kar. (2020) Language Model-Driven Chatbot for Business to Address Marketing and Selection of Products. International Working Conference on Transfer and Diffusion of IT (TDIT), Tiruchirappalli, India. pp.16-28, 10.1007/978-3-030-64849-7_3.

18. Aishwarya Ramesh, Vaibhav Chawla. (2022) Chatbots in Marketing: A Literature Review Using Morphological and Co-Occurrence Analyses. *Journal of Interactive Marketing* 2022, Vol. 57(3) 472-496.
19. 시퀀스-투-시퀀스(Sequence-to-sequence). (2023.09.26). <WikiDocs>. Available : <https://wikidocs.net/24996>
20. Tian Shi, Yaser Keneshloo, Naren Ramakrishman, and Chandan K. Reddy. (2020) Neural Abstractive Text Summarization with Sequence-to-Sequence Models. *ACM Trans. Data Sci.* 1, 1, Article 1 (January 2020), 35 pages. <https://doi.org/10.1145/3419106>
21. 트랜스포머 (Transformer). (2023.09.13). <WikiDocs>. Available : <https://wikidocs.net/31379>
22. Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Lukasz Kaiser, and Illia Polosukhin. 2017. Attention is all you need. In *Advances in Neural Information Processing Systems*, pages 6000-6010
23. 「통신지원정책과, 2022 년도 전화자동응답시스템(ARS) 운용실태 분석 및 평가결과 발표」 (과학기술정보통신부, 2023)

제 7 장 첨부서류

본 연구사업의 성과로 현재 학술지 논문을 진행 중입니다. 학술지에 게재된 이 후에 추후 첨부하겠습니다.